




Contoso Engineering (illustrative mock)

Resumo do AI Maturity Assessment

Maturidade em SDLC assistido por IA: 9 dimensões, 61 perguntas

DATA DO ASSESSMENT	2026-09-27
VERSÃO DO FRAMEWORK	2.0.2
RESPONDENTES	14
GERADO EM	2026-09-29

1. Resultado geral



Cobertura OK com 37 ou mais perguntas respondidas, WARNING a partir de 25, BLOCKED abaixo de 25.

1.1 Alertas

Risco de amplificação: D8 (L1). Essas fundações estão ao menos uma faixa abaixo do nível geral (L2). O DORA mostra que a IA amplifica forças e fraquezas existentes [3].
Diferença de percepção: D1 (3,45 / 2,50), D2 (2,69 / 2,02), D3 (2,58 / 1,80), D5 (2,60 / 1,80), D6 (2,38 / 1,59), D7 (2,33 / 1,45), D8 (1,91 / 0,79), D9 (2,10 / 1,31). Valores: score de executivos / hands-on. Impacto autodeclarado pode diferir do impacto medido [35]; confirme com telemetria.
Baixa confiança: D6. Mais de 30% das respostas são NA.
L3/L4 não verificados: D1-Q1, D1-Q3, D1-Q4, D1-Q5, D1-Q7, D4-Q1, D4-Q3, D4-Q4, D4-Q5, D4-Q6, D4-Q7. Score L3 ou maior, mas menos da metade das respostas tem evidência. Trate como não verificado até confirmar.

2. Scores por dimensão

ID	DIMENSÃO	SCORE	NÍVEL	RESPONDIDAS	NA	PRIORIDADE
D1	Estratégia, política e governança de IA	2,82	L3 Escalando	7 / 7	5%	P3 Baixo
D2	Capacitação, habilidades e cultura	2,28	L2 Adotando	6 / 6	2%	P3 Baixo
D3	Planejar, especificar e desenhar	2,09	L2 Adotando	6 / 6	6%	P2 Médio
D4	Código e engenharia de contexto	2,72	L3 Escalando	8 / 8	7%	P3 Baixo
D5	Revisão, qualidade e testes	2,10	L2 Adotando	7 / 7	5%	P2 Médio
D6	Segurança e cadeia de suprimentos de IA baixa confiança	1,90	L2 Adotando	7 / 7	42%	P2 Médio
D7	Entregar e operar	1,75	L2 Adotando	6 / 6	5%	P2 Médio
D8	Fundamentos de engenharia (amplificadores de IA)	1,09	L1 Explorando	7 / 7	4%	P1 Alto
D9	Medição, valor e AI FinOps	1,61	L2 Adotando	7 / 7	6%	P2 Médio

2.1 Dimensões por persona

Dimensão	Todos	Gerente de engenharia / tech lead n=2 · amostra pequena	Executivo(a) (CTO, VP, Diretor(a)) n=3	Engenheiro(a) de plataforma / DevOps / SRE n=2 · amostra pequena	Gerente de produto / programa n=1 · amostra pequena	Segurança / AppSec n=1 · amostra pequena	Engenheiro(a) de software / desenvolvedor(a) n=5
D1	2,82	2,86	3,45	2,79	3,29	2,43	2,38
D2	2,28	2,33	2,69	2,50	3,00	2,00	1,83
D3	2,09	2,17	2,58	1,83	2,80	1,67	1,82
D4	2,72	2,94	3,17	2,44	3,00	2,40	2,51
D5	2,10	2,43	2,60	1,93	2,33	1,43	1,86
D6	1,90	2,29	2,38	1,71	2,00	1,25	1,58
D7	1,75	1,92	2,33	1,50	2,33	1,50	1,42
D8	1,09	1,14	1,91	0,86	1,43	1,00	0,72
D9	1,61	1,79	2,10	1,36	2,00	1,00	1,36

Persona é o papel em R-Q1. Grupos com menos de 3 respondentes são marcados como amostra pequena.

2.2 Checagem cruzada de evidências

Scan de repositórios (D4-Q4, D4-Q5)

12 repositórios: 3 sem configuração, 5 com base (grounded), 3 com agentes e 1 com orquestração nos níveis RAMP [47] (scan por padrões de arquivo). 75% têm instruções ou configuração de IA versionadas, então a cobertura dos repositórios sustenta no máximo L3 para

D4-Q4. 4 de 8 arquivos de instruções foram versionados uma vez e nunca alterados. 33% dos repositórios têm custom agents, prompt files ou skills (contexto para D4-Q5).

Assessment: D4-Q4 = 2,50 (L3). Assessment: D4-Q5 = 2,79 (L3). Coerente com as respostas.

Métricas de uso do Copilot (D4-Q1, D9-Q1)

Dia do relatório 2026-09-27: 140 usuários na janela de 28 dias; 71% Code first ou acima, 21% Agent first ou acima e 4% Multi-agent [6]. Pelo sinal agêntico da escala, isso sustenta no máximo L2 para D4-Q1. 60% das 200 licenças estiveram ativas nos últimos 28 dias. Existe exportação de métricas de uso, o que é evidência para D9-Q1 (adoção medida além do número de licenças).

Assessment: D4-Q1 = 2,62 (L3). Assessment: D9-Q1 = 1,79 (L2). **As respostas de D4-Q1 estão acima do que as evidências sustentam; revise-as com as evidências antes de apresentar.**

Métricas de entrega DORA (D9-Q2)

10 serviços no export: 8 têm as quatro métricas de entrega no período atual e 6 também têm um baseline de antes da adoção de IA [2], [3], [5]. Isso é 50% dos 12 serviços no escopo, então a cobertura da comparação sustenta no máximo L2 para D9-Q2. Isto checa a cobertura da medição, não o desempenho de entrega.

Assessment: D9-Q2 = 1,61 (L2). Coerente com as respostas.

2.3 Contexto do Developer Survey

De developer-survey-maturity-2026-09-29.json (5 respondentes). Apenas contexto: o survey nunca altera as notas do v2 e usa as faixas do v1, então compare as notas e não os nomes dos níveis.

DIMENSÃO DO SURVEY	NOTA DO TIME	PERGUNTAS V2 RELACIONADAS (NOTA DO ASSESSMENT)
DS-D2 Copilot Adoption	0,80 L1 Em Desenvolvimento	D4-Q1 (2,62), D4-Q2 (2,64), D9-Q1 (1,79)
DS-D3 MS/GH Tooling Breadth	2,40 L2 Definido	D4-Q3 (2,67), D4-Q6 (2,79), D3-Q2 (2,00), D6-Q1 (2,00)
DS-D4 AI Dev Practices	2,68 L3 Gerenciado	D3-Q2 (2,00), D5-Q5 (2,31), D2-Q6 (2,15)
DS-D5 Agent Concepts Mastery	2,56 L3 Gerenciado	D2-Q4 (2,21), D4-Q5 (2,79)
DS-D6 Instructions Maturity	2,31 L2 Definido	D4-Q4 (2,50), D4-Q5 (2,79)
DS-D7 Best Practices	2,91 L3 Gerenciado	D2-Q2 (2,36), D9-Q4 (1,57)
DS-D8 Security & Governance	1,92 L2 Definido	D1-Q2 (2,93), D6-Q1 (2,00), D6-Q4 (1,71), D6-Q5 (1,50), D6-Q7 (2,08)

3. Backlog inicial

As cinco perguntas com menor score, com o âncora L3 como primeira meta. Confirme cada uma com evidências antes de planejar o trabalho.

ID	PERGUNTA	SCORE	META L3	BASE
D8-Q7	Testes automatizados como sistema de controle	0,75	A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados.	[3]
D8-Q4	Ecossistema de dados saudável	0,92	Dados-chave são catalogados com responsáveis e indicadores de qualidade; a maioria das perguntas pode ser respondida em até uma hora.	[1] [2]
D8-Q5	Ambientes reproduzíveis para humanos e agentes	1,00	A maioria dos repositórios define um ambiente reproduzível; agentes usam a mesma definição.	[8]
D8-Q1	Controle de versão para tudo	1,07	Todos os cinco tipos de ativos são versionados para a maioria dos serviços.	[1] [2]
D8-Q2	Frequência de commit e rollback rápido	1,23	A maioria dos engenheiros faz commit pelo menos diariamente; reverter uma mudança é rotina e rápido.	[2]

3.1 Estratégias recomendadas

#	ESTRATÉGIA	PRIORIDADE ACUMULADA	PRIORIDADE	HORIZONTE	PRIMEIRA AÇÃO	BASE
1	S2 Foundry + SRE D8, D9, D7	4,55	P1 Alto	Próximo trimestre	Comece por D8-Q7 (Testes automatizados como sistema de controle). Meta da âncora L3: A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados.	[1][2] [3][8]
2	S5 GitHub Copilot Acceleration D9, D3, D5, D2, D4, D1	4,39	P2 Médio	Semestre	Comece por D9-Q3 (Métricas de fluxo de pull request). Meta da âncora L3: Métricas de ciclo de vida de PR são reportadas por organização; PRs criados por agentes são identificados separadamente, incluindo sua taxa de correções pós-merge.	[2][6] [18] [28] [32] [34] [44] [50]
3	S3 App Modernization D8, D3	2,83	P1 Alto	Próximo trimestre	Comece por D8-Q7 (Testes automatizados como sistema de controle). Meta da âncora L3: A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados.	[1][2] [3][8]
4	S6 Agentic Activation D7, D6, D4, D1	2,81	P2 Médio	Semestre	Comece por D6-Q5 (AI supply chain). Meta da âncora L3: Um processo de review cobre componentes de IA; SBOMs e proveniência de build são produzidos para a maioria dos builds.	[19] [32] [38] [39] [40] [43] [45] [52]
5	S7 Security & Governance D6, D5, D1	2,19	P2 Médio	Semestre	Comece por D6-Q5 (AI supply chain). Meta da âncora L3:	[7] [19] [38]

					Um processo de review cobre componentes de IA; SBOMs e proveniência de build são produzidos para a maioria dos builds.	[39] [40] [43] [52]
6	S1 GitHub Migration D8	1,91	P1 Alto	Próximo trimestre	Comece por D8-Q7 (Testes automatizados como sistema de controle). Meta da âncora L3: A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados.	[1][2] [3][8]

Não recomendadas agora: S4 (monitorar (apenas gaps de baixa prioridade))

4. Método

NÍVEL	FAIXA DE SCORE
L0 Não iniciado	[0,0; 0,8)
L1 Explorando	[0,8; 1,6)
L2 Adotando	[1,6; 2,4)
L3 Escalando	[2,4; 3,2)
L4 Nativo em IA	[3,2; 4,0]

Score da pergunta: média dos respondentes (NA excluído). Score da dimensão: média das perguntas. Geral: média ponderada das dimensões (pesos iguais por padrão). Gap = alvo (3,0 por padrão) menos score; prioridade = peso × gap: P0 a partir de 2,4, P1 a partir de 1,6, P2 a partir de 0,9.

As respostas são percepções. Triangule D4, D5 e D9 com telemetria e evidências antes de apresentar resultados. Limiares e pesos são escolhas de design do kit, não um padrão da indústria.

5. Referências

- [1] DORA. DORA AI Capabilities Model. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/report/>
- [2] DORA. DORA AI Capabilities Model: Survey Questions. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/questions/>
- [3] Google Cloud. Announcing the 2025 DORA Report: State of AI-Assisted Software Development. 2025. <https://cloud.google.com/blog/products/ai-machine-learning/announcing-the-2025-dora-report>
- [6] GitHub Docs. GitHub Copilot usage metrics. <https://docs.github.com/en/copilot/concepts/billing-and-usage/copilot-usage-metrics/copilot-metrics>
- [7] GitHub Docs. Risks and mitigations for GitHub Copilot cloud agent. <https://docs.github.com/en/enterprise-cloud@latest/copilot/concepts/security-governance-and-network-settings/risks-and-mitigations>
- [8] GitHub Docs. Best practices for using GitHub Copilot to work on tasks. <https://docs.github.com/en/enterprise-cloud@latest/copilot/tutorials/cloud-agent/get-the-best-results>
- [12] GitHub Docs. About GitHub Copilot code review. <https://docs.github.com/en/copilot/concepts/agents/code-review>
- [14] GitHub Docs. Application card: GitHub Copilot Agents. <https://docs.github.com/en/copilot/responsible-use/agents>
- [15] GitHub Docs. Managing policies and features for GitHub Copilot in your organization. <https://docs.github.com/en/copilot/how-tos/administer-copilot/manage-for-organization/manage-policies>
- [16] Microsoft Azure Blog. Agentic DevOps: Evolving software development with GitHub Copilot and Microsoft Azure. 2025. <https://azure.microsoft.com/en-us/blog/agentic-devops-evolving-software-development-with-github-copilot-and-microsoft-azure/>
- [17] Microsoft for Developers. Agentic DevOps in action: Reimagining every phase of the developer lifecycle. 2025. <https://developer.microsoft.com/blog/reimagining-every-phase-of-the-developer-lifecycle/>
- [18] Microsoft Learn. AI strategy: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/strategy>
- [19] Microsoft Learn. Govern and secure AI agents: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai-agents/governance-security-across-organization>
- [20] Microsoft Learn. Responsible AI policies: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/responsible-ai-policies>
- [21] Microsoft. Responsible AI Principles and Approach. <https://www.microsoft.com/en-us/ai/principles-and-approach>
- [22] Microsoft Azure Blog. Announcing Azure Copilot agents and AI infrastructure innovations. 2025. <https://azure.microsoft.com/en-us/blog/announcing-azure-copilot-agents-and-ai-infrastructure-innovations/>
- [23] Anthropic. Anthropic Economic Index: AI's impact on software development. 2025-04-28. <https://www.anthropic.com/research/impact-software-development>
- [24] Anthropic. How Claude Code is used in practice. 2026-06-16. <https://www.anthropic.com/research/claude-code-expertise>
- [25] Anthropic. Effective context engineering for AI agents. 2025-09-29. <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
- [26] Anthropic. Building effective agents. 2024-12-19. <https://www.anthropic.com/engineering/building-effective-agents>
- [27] Anthropic. Best practices for Claude Code. Claude Code Docs. <https://code.claude.com/docs/en/best-practices>
- [28] Gartner. Gartner Says 75% of Enterprise Software Engineers Will Use AI Code Assistants by 2028. 2024-04-11. <https://www.gartner.com/en/newsroom/press-releases/2024-04-11-gartner-says-75-percent-of-enterprise-software-engineers-will-use-ai-code-assistants-by-2028>
- [30] Gartner. Gartner Says Generative AI will Require 80% of Engineering Workforce to Upskill Through 2027. 2024-10-03. <https://www.gartner.com/en/newsroom/press-releases/2024-10-03-gartner-says-generative-ai-will-require-80-percent-of-engineering-workforce-to-upskill-through-2027>

- [31] Gartner. Gartner Says the Market for Enterprise AI Coding Agents Is Entering a New Phase of Expansion and Competitive Realignment. 2026-05-20. <https://www.gartner.com/en/newsroom/press-releases/2026-05-20-gartner-says-the-market-for-enterprise-ai-coding-agents-is-entering-a-new-phase-of-expansion-and-competitive-realignment>
- [32] Gartner. Gartner Predicts AI Coding Costs Will Surpass Average Developer's Salary by 2028 as Token Consumption Surges. 2026-06-24. <https://www.gartner.com/en/newsroom/press-releases/2026-06-24-gartner-predicts-ai-coding-costs-will-surpass-average-developer-salary-by-2028-as-token-consumption-surges>
- [34] Cui, Z. K., Demirer, M., Jaffe, S., Musolff, L., Peng, S., Salz, T. The Effects of Generative AI on High-Skilled Work: Evidence from Three Field Experiments with Software Developers. *Management Science*, published online 2026-02-27. <https://doi.org/10.1287/mnsc.2025.00535> (pre-print: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4945566)
- [35] METR. Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity. 2025-07-10. <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/> (paper: <https://arxiv.org/abs/2507.09089>)
- [37] Stack Overflow. 2025 Developer Survey: AI. <https://survey.stackoverflow.co/2025/ai>
- [38] OWASP GenAI Security Project. OWASP Top 10 for LLM Applications 2025. <https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/>
- [39] OWASP GenAI Security Project. OWASP Top 10 for Agentic Applications for 2026. 2025-12-09. <https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/>
- [40] NIST. SP 800-218A: Secure Software Development Practices for Generative AI and Dual-Use Foundation Models: An SSDF Community Profile. 2024-07. <https://csrc.nist.gov/pubs/sp/800/218/a/final>
- [41] NIST. AI Risk Management Framework. <https://www.nist.gov/itl/ai-risk-management-framework>
- [42] ISO. ISO/IEC 42001:2023: AI management systems. <https://www.iso.org/standard/42001>
- [43] OpenSSF. SLSA: Supply-chain Levels for Software Artifacts. <https://slsa.dev/>
- [44] Forsgren, N., Storey, M.-A., Maddila, C., Zimmermann, T., Houck, B., Butler, J. The SPACE of Developer Productivity. *ACM Queue* 19(1), 2021-03-06. <https://queue.acm.org/detail.cfm?id=3454124> (DOI: <https://doi.org/10.1145/3454122.3454124>)
- [45] Liu, B., Qiu, H., Goiri, Í., Fonseca, R., Bianchini, R., Choukse, E. Agentic Coding in the Wild: Characterizing GitHub Copilot Traces at Production Scale. *arXiv:2608.00101*, 2026-07-30. <https://arxiv.org/abs/2608.00101>
- [46] Arabat, A., Sayagh, M. Toward Instructions-as-Code: Understanding the Impact of Instruction Files on Agentic Pull Requests. *arXiv:2606.13449*, 2026-06-11. <https://arxiv.org/abs/2606.13449>
- [47] Denisov-Blanch, Y., Agarwal, S., Azaletskiy, P., He, H., Schaeffer, R., Miranda, B., Vasilescu, B., Koyejo, S. A Few Pages of Markdown: Committed AI Configuration and Lower Quality Cost after Coding-Agent Adoption. *arXiv:2608.25241*, 2026-08-26. <https://arxiv.org/abs/2608.25241>
- [48] Shen, J. H., Tamkin, A. How AI Impacts Skill Formation. *arXiv:2601.20245*, 2026-01-28. <https://arxiv.org/abs/2601.20245> (Anthropic summary: <https://www.anthropic.com/research/AI-assistance-coding-skills>)
- [49] Pinna, G., Gong, J., Williams, D., Sarro, F. Comparing AI Coding Agents: A Task-Stratified Analysis of Pull Request Acceptance. *arXiv:2602.08915*, 2026-02-09. <https://arxiv.org/abs/2602.08915>
- [50] Takerngsaksiri, W., Duong, N., Barnett, S. Who Finishes the Job? A Study of Follow-Up Fixes and Commit Authorship on AI Coding Agent Pull Requests. *arXiv:2609.26847*, 2026-09-22. <https://arxiv.org/abs/2609.26847>
- [52] Sakib, A. H. M. N., Banik, D., Jadliwala, M. Trust but Verify? Uncovering the Security Debt of Autonomous Coding Agents. *arXiv:2607.12428*, 2026-07-14. <https://arxiv.org/abs/2607.12428>
- [54] Selvanayagam, N., Ghaleb, T. A. AI-to-AI Code Reviews of GitHub Pull Requests. *arXiv:2608.21311*, 2026-08-21. <https://arxiv.org/abs/2608.21311>
- [55] Stolze, M., Strässle, M. When Review Alone No Longer Scales: Layered Supervision in AI-Assisted Software Engineering. *arXiv:2608.26316*, 2026-08-26. <https://arxiv.org/abs/2608.26316>
- [56] Monperrus, M. The End of Code Review: Coding Agents Supersede Human Inspection. *arXiv:2606.13175*, 2026-06-11. <https://arxiv.org/abs/2606.13175>
- [58] Farrag, S. E. The Productivity-Reliability Paradox: Specification-Driven Governance for AI-Augmented Software Development. *arXiv:2605.01160*, 2026-05-01. <https://arxiv.org/abs/2605.01160>