




Contoso Engineering (illustrative mock)

Guia de implementação

Da avaliação à execução: governança, plano por fases, gestão da mudança e os primeiros 90 dias

DATA DO ASSESSMENT	2026-09-27
VERSÃO DO FRAMEWORK	2.0.2
RESPONDENTES	14
GERADO EM	2026-09-29

1. Resumo executivo



Contoso Engineering (illustrative mock) obteve 2,04 (L2 Adotando) com 14 respondentes. 9 de 9 dimensões estão abaixo da meta de 3,0. O plano ordena o trabalho por prioridade (peso × gap) e começa pelas perguntas de menor nota de cada dimensão; cada item termina quando a âncora L3 é atendida e confirmada com evidências.

1.1 Tratar antes de assumir metas

Fundamentos fracos: D8
Gap de percepção: D1, D2, D3, D5, D6, D7, D8, D9
Baixa confiança: D6
Pontos fortes não verificados: D1-Q1, D1-Q3, D1-Q4, D1-Q5, D1-Q7, D4-Q1, D4-Q3, D4-Q4, D4-Q5, D4-Q6, D4-Q7
Telemetria abaixo das respostas: D4-Q1

Entradas do wizard: 55% preenchidas.

2. Governança

2.1 Comitê diretivo

Patrocina o programa, aprova metas e investimento e remove bloqueios.

NOME	PAPEL
Maria Tech Leader	Champion (maria.tl@cliente-exemplo.com.br)
Joao Backend SRE	Champion (joao.sre@cliente-exemplo.com.br)
Sofia Frontend Lead	Champion (sofia.fe@cliente-exemplo.com.br)

2.2 Escritório do programa

Conduz o plano semana a semana, mantém o backlog e reporta o progresso ao comitê diretivo.

A preencher com o cliente

2.3 Responsáveis por dimensão

Um responsável (accountable) para cada dimensão abaixo da meta.

ID	DIMENSÃO	PRIORIDADE	HORIZONTE	RESPONSÁVEL
D1	Estratégia, política e governança de IA	P3 Baixo	Backlog / monitorar	A preencher com o cliente
D2	Capacitação, habilidades e cultura	P3 Baixo	Backlog / monitorar	A preencher com o cliente
D3	Planejar, especificar e desenhar	P2 Médio	Semestre	A preencher com o cliente
D4	Código e engenharia de contexto	P3 Baixo	Backlog / monitorar	A preencher com o cliente
D5	Revisão, qualidade e testes	P2 Médio	Semestre	A preencher com o cliente
D6	Segurança e cadeia de suprimentos de IA	P2 Médio	Semestre	A preencher com o cliente
D7	Entregar e operar	P2 Médio	Semestre	A preencher com o cliente
D8	Fundamentos de engenharia (amplificadores de IA)	P1 Alto	Próximo trimestre	A preencher com o cliente
D9	Medição, valor e AI FinOps	P2 Médio	Semestre	A preencher com o cliente

2.4 RACI

A preencher com o cliente

3. Plano por fases

Cada dimensão abaixo da meta fica no horizonte dado pela prioridade: P0 em 30 dias, P1 no próximo trimestre, P2 no semestre, P3 no backlog. Comece pelas perguntas listadas; um item termina quando a âncora L3 é atendida e as evidências listadas a confirmam.

3.1 P1: Próximo trimestre

D8: Fundamentos de engenharia (amplificadores de IA) (1,09 → 3,0, P1 Alto)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D8-Q7	Testes automatizados como sistema de controle KPI: % de serviços que atendem à âncora L3	0,75	A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados. [3]	Inventário de suites de teste, durações de pipeline, dados de defeitos escapados.
D8-Q4	Ecossistema de dados saudável KPI: Nível da prática em toda a organização	0,92	Dados-chave são catalogados com responsáveis e indicadores de qualidade; a maioria das perguntas pode ser respondida em até uma hora. [1][2]	Catálogo de dados, dashboards de qualidade.
D8-Q5	Ambientes reproduzíveis para humanos e agentes KPI: % de repositórios que atendem à âncora L3	1,00	A maioria dos repositórios define um ambiente reproduzível; agentes usam a mesma definição. [8]	Arquivos devcontainer, tempos de start-up de ambiente.

Estratégias deste horizonte

- **S2 Foundry + SRE, S3 App Modernization, S1 GitHub Migration:** Comece por D8-Q7 (Testes automatizados como sistema de controle). Meta da âncora L3: A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados.

3.2 P2: Semestre

D3: Planejar, especificar e desenhar (2,09 → 3,0, P2 Médio)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D3-Q1	IA no refinamento de backlog KPI: % de equipes que atendem à âncora L3	2,00	A maioria das equipes usa IA para redigir ou melhorar itens de trabalho; critérios de aceite são obrigatórios antes do trabalho começar. [16][17]	Templates de issue, exemplos de itens de trabalho, verificações de qualidade.
D3-Q2	Especificação antes da implementação KPI: % de equipes que atendem à âncora L3	2,00	Planos ou specs são armazenados no repositório ou vinculados à issue, e são revisados por um humano antes da implementação pelo agente. [23][24][27][58]	Arquivos de spec, reviews de plano, PRs que referenciam specs.
D3-Q5	Foco centrado no usuário KPI: % de equipes que atendem à âncora L3	2,07	Itens de trabalho referenciam o problema do usuário e a medida de sucesso; feedback é revisado antes da priorização. [1][2][3]	Briefs de produto, registros de loop de feedback, dashboards de resultados.

D5: Revisão, qualidade e testes (2,10 → 3,0, P2 Médio)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D5-Q6	Cultura de verificação e confiança calibrada KPI: % de equipes que atendem à âncora L3	1,77	Diretrizes de review explicam o que verificar na saída de IA; confiança na saída de IA faz parte da pesquisa com desenvolvedores. [3][23][35][37][48][52]	Diretrizes de review, resultados de pesquisa, análise de defeitos.
D5-Q3	Mesmos quality gates para code de IA e humano KPI: % de repositórios que atendem à âncora L3	2,00	Checks exigidos são aplicados por rulesets nos protected branches da maioria dos repositórios, sem bypass para identidades de agentes. [3][7][31][50][55]	Rulesets, checks exigidos, listas de bypass.
D5-Q1	AI-assisted code review KPI: % de repositórios que atendem à âncora L3	2,07	AI review executa automaticamente na maioria dos PRs; equipes rastreiam sugestões úteis versus descartadas. [6][12][14][54][55]	Rulesets de repositório, métricas de adoção de code review, resultados de sugestões.

D6: Segurança e cadeia de suprimentos de IA (1,90 → 3,0, P2 Médio)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D6-Q5	AI supply chain KPI: % de repositórios que atendem à âncora L3	1,50	Um processo de review cobre componentes de IA; SBOMs e proveniência de build são produzidos para a maioria dos builds. [38][40][43][52]	Registros de review de componentes, amostras de SBOM e atestação.
D6-Q6	Threat modeling para features e agentes de IA KPI: % de serviços que atendem à âncora L3	1,62	Threat models são exigidos para novas features de IA e workflows de agentes, e revisados por segurança. [38][39][40]	Documentos de threat model, registros de security review.
D6-Q4	Least privilege para agentes KPI: Nível da prática em toda a organização	1,71	Permissões de agentes são documentadas e revisadas; agentes não conseguem acessar credenciais de produção nem fazer push para protected branches. [7][19][38][39]	Configuração de ambiente de agentes, escopos de token, revisões de acesso.

D7: Entregar e operar (1,75 → 3,0, P2 Médio)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D7-Q4	Observabilidade de agentes KPI: Nível da prática em toda a organização	1,57	Runs de agentes emitem telemetria para a stack central de observabilidade; dashboards mostram falhas e custo por agente. [19][32][45]	Dashboards de telemetria, regras de alerta.
D7-Q1	IA em pipelines CI/CD KPI: % de repositórios que atendem à âncora L3	1,69	Pipelines são code na maioria dos repositórios; análise de falhas assistida por IA está disponível para todas as equipes. [16][17]	Repositórios de pipeline, uso de análise de falhas, métricas de build.
D7-Q3	Resposta a incidentes assistida por IA KPI: % de serviços que atendem à âncora L3	1,71	Engenheiros de on-call na maioria das equipes usam IA para triage e resumos; revisões pós-incidente registram se a IA ajudou. [16][17][22]	Configuração de ferramentas de incidentes, timelines de incidentes, dados de tempo de restauração.

D9: Medição, valor e AI FinOps (1,61 → 3,0, P2 Médio)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D9-Q3	Métricas de fluxo de pull request KPI: Nível da prática em toda a organização	1,33	Métricas de ciclo de vida de PR são reportadas por organização; PRs criados por agentes são identificados separadamente, incluindo sua taxa de correções pós-merge. [6][34][50]	Métricas de ciclo de vida de PR, relatórios de PRs de agentes, análise de correções de acompanhamento.
D9-Q7	Vínculo com valor de negócio KPI: Nível da prática em toda a organização	1,54	Existe um business case com premissas explícitas e ele é revisado pelo menos anualmente. [18][28][32]	Business case, relatórios de valor.
D9-Q4	Developer experience e fricção KPI: Nível da prática em toda a organização	1,57	Uma pesquisa ocorre pelo menos duas vezes por ano com boa participação; resultados são compartilhados e geram ações. [2][44]	Instrumento de pesquisa, taxa de participação, log de ações.

Estratégias deste horizonte

- **S5 GitHub Copilot Acceleration:** Comece por D9-Q3 (Métricas de fluxo de pull request). Meta da âncora L3: Métricas de ciclo de vida de PR são reportadas por organização; PRs criados por agentes são identificados separadamente, incluindo sua taxa de correções pós-merge.
- **S6 Agentic Activation, S7 Security & Governance:** Comece por D6-Q5 (AI supply chain). Meta da âncora L3: Um processo de review cobre componentes de IA; SBOMs e proveniência de build são produzidos para a maioria dos builds.

3.3 P3: Backlog / monitorar

D1: Estratégia, política e governança de IA (2,82 → 3,0, P3 Baixo)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D1-Q5	Níveis de autonomia para trabalho com IA não verificado KPI: Nível da prática em toda a organização	2,69	Uma matriz publicada mapeia tipos de tarefa (por exemplo upgrades de dependências, geração de testes, trabalho de feature, mudanças em produção) para níveis de autonomia e aprovações exigidas. [7][26][32][49][56]	Matriz de autonomia, rulesets de repositório, registros de mudança.
D1-Q6	IA responsável e framework de risco KPI: Nível da prática em toda a organização	2,71	Um framework nomeado é adotado; riscos relacionados a IA estão no registro de riscos com responsáveis e revisões. [20][21][41][42]	Mapeamento do framework, entradas no registro de riscos, relatórios de auditoria.
D1-Q3	Ferramentas e modelos aprovados não verificado KPI: Nível da prática em toda a organização	2,75	Políticas enterprise/da organização habilitam apenas recursos e modelos aprovados; o catálogo lista responsável, tratamento de dados e data de revisão para cada ferramenta. [2][15][32][49]	Configurações de política do Copilot, catálogo de ferramentas, registros de avaliação de modelos.

D2: Capacitação, habilidades e cultura (2,28 → 3,0, P3 Baixo)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D2-Q1	Treinamento estruturado de IA KPI: % de engenheiros que atendem à âncora L3	2,15	Currículo baseado em função (desenvolvedor, revisor, plataforma, segurança) com conclusão rastreada; o treinamento é exigido antes que recursos de agentes sejam habilitados; ensina padrões que preservam o aprendizado (pedir explicações, tentar primeiro, depois comparar) e não apenas delegação total. [2][30][48]	Trilhas de aprendizagem, taxas de conclusão, regras de bloqueio de habilitação.
D2-Q6	Onboarding assistido por IA KPI: % de engenheiros que atendem à âncora L3	2,15	O onboarding inclui tours de codebase guiados por IA e instruções de repositório; tempo até o primeiro PR mergeado é rastreado; novos engenheiros são avaliados em leitura de code e debugging, não apenas em saída. [27][48]	Playbook de onboarding, dados de tempo até primeiro PR, resultados de verificação de habilidades.
D2-Q4	Habilidades de engenharia de contexto KPI: % de engenheiros que atendem à âncora L3	2,21	Orientações e exemplos sobre engenharia de contexto fazem parte do treinamento; equipes revisam suas instruções e prompts quanto à qualidade. [25][30][32]	Páginas de orientação, checklists de review, métricas antes/depois.

D4: Código e engenharia de contexto (2,72 → 3,0, P3 Baixo)

ID	PERGUNTA	SCORE	PRONTO QUANDO (ÂNCORA L3)	EVIDÊNCIAS A COLETAR
D4-Q4	Instruções de repositório não verificado KPI: % de repositórios que atendem à âncora L3	2,50	A maioria dos repositórios ativos tem instruções estruturadas (build, test, convenções, restrições) com um responsável; mudanças passam por PR review; arquivos são atualizados quando o codebase muda, em vez de serem commitados uma vez. [2][8][25][27][46][47][55]	Arquivos de instrução, cobertura entre repositórios, histórico de mudanças, métricas antes/depois de PRs de agentes.
D4-Q1	Profundidade do uso de IA entre superfícies não verificado KPI: % de engenheiros que atendem à âncora L3	2,62	Muitos engenheiros usam regularmente pelo menos uma superfície de agente do GitHub ("Agent first"), confirmado por métricas de uso. [6]	Dashboard ou API de métricas de uso do Copilot: distribuição de coortes de adoção, usuários ativos diários/semanais.
D4-Q2	Modo agente para trabalho multi-file KPI: % de engenheiros que atendem à âncora L3	2,64	Agent mode é o padrão para refactors e features multi-file na maioria das equipes; mudanças são revisadas no diff antes do commit. [6][27]	Uso por feature/mode, diretrizes da equipe.

4. Gestão da mudança

4.1 Plano ADKAR

Consciência, Desejo, Conhecimento, Habilidade e Reforço: as intervenções planejadas para cada etapa.

Plano de Mudança ADKAR derivado do Learning Survey:

Awareness: Comunicar plano de capacitação consolidado em all-hands; cada dev recebe seu plano personalizado por email.

Desire: Tornar visível que workshops têm inscritos pré-validados (não opt-in genérico).

Knowledge: Workshops top 5 (do Learning Survey):

- 1. Copilot Spaces (contexto compartilhado) (5 inscritos)
- 2. A2A (Agent-to-Agent) protocol (4 inscritos)
- 3. Microsoft Foundry, visão geral (4 inscritos)
- 4. Documentação automática (4 inscritos)
- 5. Modo Ask (perguntas eficazes) (3 inscritos)

Ability: Office hours quinzenal (sem agenda fixa, devs trazem dúvidas práticas).

Reinforcement: Métricas de adoção mensais publicadas; reconhecimento dos Champions; revisão trimestral do plano com novo Learning Survey.

4.2 Plano de comunicação

PÚBLICO	CANAL	FREQUÊNCIA	RESPONSÁVEL
Champions Kickoff (3)	2h síncrono	W1	Líder Eng
Copilot Spaces (contexto compartilhado) (5)	4h hands-on	W2	Maria Tech Leader
A2A (Agent-to-Agent) protocol (4)	4h hands-on	W3	Maria Tech Leader
Microsoft Foundry, visão geral (4)	4h hands-on	W4	Maria Tech Leader
Office hours #1 (Todos)	1h Q&A	W4	Champions
Office hours quinzenal (Todos)	1h Q&A	W6, W8, W10, W12	Champions

4.3 Plano de capacitação

D2 Capacitação, habilidades e cultura obteve 2,28 (L2 Adotando). Monte as turmas de capacitação a partir do Learning and Growth Survey (/training-plan) e acompanhe-as em D2. Plano de capacitação encontrado: output/training-plan-2026-09-29.md.

PÚBLICO	FORMATO	CADÊNCIA
DS-D2 (Copilot Adoption): 3 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced
DS-D3 (MS/GH Tooling Breadth): 3 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced
DS-D4 (AI Dev Practices): 1 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced
DS-D5 (Agent Concepts Mastery): 2 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced
DS-D6 (Instructions Maturity): 4 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced
DS-D7 (Best Practices): 3 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced
DS-D8 (Security & Governance): 2 devs	Self-paced (meu ritmo, mais flexibilidade)	cohort de 4-6 semanas com sessões síncronas + lab self-paced

5. Riscos

Riscos apontados pelas regras de pontuação e, em seguida, o registro de riscos do próprio cliente.

RISCO	AFETA	MITIGAÇÃO
Fundamentos fracos Dimensões amplificadoras estão pelo menos uma faixa abaixo do nível geral. O DORA conclui que a IA amplifica forças e fraquezas existentes [3].	D8	Eleve essas dimensões antes de escalar a adoção de IA.
Gap de percepção Executivos avaliam essas dimensões pelo menos uma faixa acima dos engenheiros hands-on.	D1, D2, D3, D5, D6, D7, D8, D9	Revise o gap com os dois grupos e confirme com telemetria e evidências antes de definir metas.
Baixa confiança Mais de 30% das respostas são NA nessas dimensões.	D6	Encontre respondentes que conheçam essas práticas e pergunte novamente.
Pontos fortes não verificados Nota L3 ou maior, mas menos da metade das respostas traz evidências.	D1-Q1, D1-Q3, D1-Q4, D1-Q5, D1-Q7, D4-Q1, D4-Q3, D4-Q4, D4-Q5, D4-Q6, D4-Q7	Confirme com evidências antes de apresentar essas perguntas como pontos fortes.
Telemetria abaixo das respostas As métricas de uso do Copilot sustentam um nível de D4-Q1 menor que o das respostas.	D4-Q1	Revise D4-Q1 com a telemetria e defina metas de adoção a partir dela.

5.1 Registro de riscos do cliente

A preencher com o cliente

6. Métricas de sucesso e reavaliação

Nota atual e meta de cada dimensão abaixo da meta. O KPI de cada item está no plano por fases.

ID	DIMENSÃO	SCORE	ALVO	GAP	HORIZONTE
D1	Estratégia, política e governança de IA	2,82	3,0	0,18	Backlog / monitorar
D2	Capacitação, habilidades e cultura	2,28	3,0	0,72	Backlog / monitorar
D3	Planejar, especificar e desenhar	2,09	3,0	0,91	Semestre
D4	Código e engenharia de contexto	2,72	3,0	0,28	Backlog / monitorar
D5	Revisão, qualidade e testes	2,10	3,0	0,90	Semestre
D6	Segurança e cadeia de suprimentos de IA	1,90	3,0	1,10	Semestre
D7	Entregar e operar	1,75	3,0	1,25	Semestre
D8	Fundamentos de engenharia (amplificadores de IA)	1,09	3,0	1,91	Próximo trimestre
D9	Medição, valor e AI FinOps	1,61	3,0	1,39	Semestre

- Reavalie ao fim de cada horizonte com o mesmo formulário e compare as rodadas com make compare BEFORE=... AFTER=... (o PDF de comparação mostra as variações).
- Quando houver, confirme D4 e D9 com as métricas de uso do Copilot [6] e métricas de entrega (D9-Q2) antes de reportar progresso.

7. Primeiros 90 dias

7.1 Semanas 1 a 4

1. W1: Champions Kickoff
2. W2: Copilot Spaces (contexto compartilhado)
3. W3: A2A (Agent-to-Agent) protocol
4. W4: Microsoft Foundry, visão geral
5. W4: Office hours #1

7.2 Semanas 5 a 8

- Iniciar S2 Foundry + SRE: Comece por D8-Q7 (Testes automatizados como sistema de controle). Meta da âncora L3: A maioria dos serviços tem testes automatizados em camadas que executam em todo PR dentro de time budgets acordados.
- Iniciar S5 GitHub Copilot Acceleration: Comece por D9-Q3 (Métricas de fluxo de pull request). Meta da âncora L3: Métricas de ciclo de vida de PR são reportadas por organização; PRs criados por agentes são identificados separadamente, incluindo sua taxa de correções pós-merge.

7.3 Semanas 9 a 12

1. W10: Office hours quinzenal

8. Referências

- [1] DORA. DORA AI Capabilities Model. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/report/>
- [2] DORA. DORA AI Capabilities Model: Survey Questions. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/questions/>
- [3] Google Cloud. Announcing the 2025 DORA Report: State of AI-Assisted Software Development. 2025. <https://cloud.google.com/blog/products/ai-machine-learning/announcing-the-2025-dora-report>
- [6] GitHub Docs. GitHub Copilot usage metrics. <https://docs.github.com/en/copilot/concepts/billing-and-usage/copilot-usage-metrics/copilot-metrics>
- [7] GitHub Docs. Risks and mitigations for GitHub Copilot cloud agent. <https://docs.github.com/en/enterprise-cloud@latest/copilot/concepts/security-governance-and-network-settings/risks-and-mitigations>
- [8] GitHub Docs. Best practices for using GitHub Copilot to work on tasks. <https://docs.github.com/en/enterprise-cloud@latest/copilot/tutorials/cloud-agent/get-the-best-results>
- [12] GitHub Docs. About GitHub Copilot code review. <https://docs.github.com/en/copilot/concepts/agents/code-review>
- [14] GitHub Docs. Application card: GitHub Copilot Agents. <https://docs.github.com/en/copilot/responsible-use/agents>
- [15] GitHub Docs. Managing policies and features for GitHub Copilot in your organization. <https://docs.github.com/en/copilot/how-tos/administer-copilot/manage-for-organization/manage-policies>
- [16] Microsoft Azure Blog. Agentic DevOps: Evolving software development with GitHub Copilot and Microsoft Azure. 2025. <https://azure.microsoft.com/en-us/blog/agentic-devops-evolving-software-development-with-github-copilot-and-microsoft-azure/>
- [17] Microsoft for Developers. Agentic DevOps in action: Reimagining every phase of the developer lifecycle. 2025. <https://developer.microsoft.com/blog/reimagining-every-phase-of-the-developer-lifecycle/>
- [18] Microsoft Learn. AI strategy: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/strategy>
- [19] Microsoft Learn. Govern and secure AI agents: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai-agents/governance-security-across-organization>
- [20] Microsoft Learn. Responsible AI policies: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/responsible-ai-policies>
- [21] Microsoft. Responsible AI Principles and Approach. <https://www.microsoft.com/en-us/ai/principles-and-approach>
- [22] Microsoft Azure Blog. Announcing Azure Copilot agents and AI infrastructure innovations. 2025. <https://azure.microsoft.com/en-us/blog/announcing-azure-copilot-agents-and-ai-infrastructure-innovations/>
- [23] Anthropic. Anthropic Economic Index: AI's impact on software development. 2025-04-28. <https://www.anthropic.com/research/impact-software-development>
- [24] Anthropic. How Claude Code is used in practice. 2026-06-16. <https://www.anthropic.com/research/claude-code-expertise>
- [25] Anthropic. Effective context engineering for AI agents. 2025-09-29. <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
- [26] Anthropic. Building effective agents. 2024-12-19. <https://www.anthropic.com/engineering/building-effective-agents>
- [27] Anthropic. Best practices for Claude Code. Claude Code Docs. <https://code.claude.com/docs/en/best-practices>
- [28] Gartner. Gartner Says 75% of Enterprise Software Engineers Will Use AI Code Assistants by 2028. 2024-04-11. <https://www.gartner.com/en/newsroom/press-releases/2024-04-11-gartner-says-75-percent-of-enterprise-software-engineers-will-use-ai-code-assistants-by-2028>
- [30] Gartner. Gartner Says Generative AI will Require 80% of Engineering Workforce to Upskill Through 2027. 2024-10-03. <https://www.gartner.com/en/newsroom/press-releases/2024-10-03-gartner-says-generative-ai-will-require-80-percent-of-engineering-workforce-to-upskill-through-2027>

- [31] Gartner. Gartner Says the Market for Enterprise AI Coding Agents Is Entering a New Phase of Expansion and Competitive Realignment. 2026-05-20. <https://www.gartner.com/en/newsroom/press-releases/2026-05-20-gartner-says-the-market-for-enterprise-ai-coding-agents-is-entering-a-new-phase-of-expansion-and-competitive-realignment>
- [32] Gartner. Gartner Predicts AI Coding Costs Will Surpass Average Developer's Salary by 2028 as Token Consumption Surges. 2026-06-24. <https://www.gartner.com/en/newsroom/press-releases/2026-06-24-gartner-predicts-ai-coding-costs-will-surpass-average-developer-salary-by-2028-as-token-consumption-surges>
- [34] Cui, Z. K., Demirer, M., Jaffe, S., Musolff, L., Peng, S., Salz, T. The Effects of Generative AI on High-Skilled Work: Evidence from Three Field Experiments with Software Developers. *Management Science*, published online 2026-02-27. <https://doi.org/10.1287/mnsc.2025.00535> (pre-print: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4945566)
- [35] METR. Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity. 2025-07-10. <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/> (paper: <https://arxiv.org/abs/2507.09089>)
- [37] Stack Overflow. 2025 Developer Survey: AI. <https://survey.stackoverflow.co/2025/ai>
- [38] OWASP GenAI Security Project. OWASP Top 10 for LLM Applications 2025. <https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/>
- [39] OWASP GenAI Security Project. OWASP Top 10 for Agentic Applications for 2026. 2025-12-09. <https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/>
- [40] NIST. SP 800-218A: Secure Software Development Practices for Generative AI and Dual-Use Foundation Models: An SSDF Community Profile. 2024-07. <https://csrc.nist.gov/pubs/sp/800/218/a/final>
- [41] NIST. AI Risk Management Framework. <https://www.nist.gov/itl/ai-risk-management-framework>
- [42] ISO. ISO/IEC 42001:2023: AI management systems. <https://www.iso.org/standard/42001>
- [43] OpenSSF. SLSA: Supply-chain Levels for Software Artifacts. <https://slsa.dev/>
- [44] Forsgren, N., Storey, M.-A., Maddila, C., Zimmermann, T., Houck, B., Butler, J. The SPACE of Developer Productivity. *ACM Queue* 19(1), 2021-03-06. <https://queue.acm.org/detail.cfm?id=3454124> (DOI: <https://doi.org/10.1145/3454122.3454124>)
- [45] Liu, B., Qiu, H., Goiri, Í., Fonseca, R., Bianchini, R., Choukse, E. Agentic Coding in the Wild: Characterizing GitHub Copilot Traces at Production Scale. arXiv:2608.00101, 2026-07-30. <https://arxiv.org/abs/2608.00101>
- [46] Arabat, A., Sayagh, M. Toward Instructions-as-Code: Understanding the Impact of Instruction Files on Agentic Pull Requests. arXiv:2606.13449, 2026-06-11. <https://arxiv.org/abs/2606.13449>
- [47] Denisov-Blanch, Y., Agarwal, S., Azaletskiy, P., He, H., Schaeffer, R., Miranda, B., Vasilescu, B., Koyejo, S. A Few Pages of Markdown: Committed AI Configuration and Lower Quality Cost after Coding-Agent Adoption. arXiv:2608.25241, 2026-08-26. <https://arxiv.org/abs/2608.25241>
- [48] Shen, J. H., Tamkin, A. How AI Impacts Skill Formation. arXiv:2601.20245, 2026-01-28. <https://arxiv.org/abs/2601.20245> (Anthropic summary: <https://www.anthropic.com/research/AI-assistance-coding-skills>)
- [49] Pinna, G., Gong, J., Williams, D., Sarro, F. Comparing AI Coding Agents: A Task-Stratified Analysis of Pull Request Acceptance. arXiv:2602.08915, 2026-02-09. <https://arxiv.org/abs/2602.08915>
- [50] Takerngsaksiri, W., Duong, N., Barnett, S. Who Finishes the Job? A Study of Follow-Up Fixes and Commit Authorship on AI Coding Agent Pull Requests. arXiv:2609.26847, 2026-09-22. <https://arxiv.org/abs/2609.26847>
- [52] Sakib, A. H. M. N., Banik, D., Jadhwal, M. Trust but Verify? Uncovering the Security Debt of Autonomous Coding Agents. arXiv:2607.12428, 2026-07-14. <https://arxiv.org/abs/2607.12428>
- [54] Selvanayagam, N., Ghaleb, T. A. AI-to-AI Code Reviews of GitHub Pull Requests. arXiv:2608.21311, 2026-08-21. <https://arxiv.org/abs/2608.21311>
- [55] Stolze, M., Strässle, M. When Review Alone No Longer Scales: Layered Supervision in AI-Assisted Software Engineering. arXiv:2608.26316, 2026-08-26. <https://arxiv.org/abs/2608.26316>
- [56] Monperrus, M. The End of Code Review: Coding Agents Supersede Human Inspection. arXiv:2606.13175, 2026-06-11. <https://arxiv.org/abs/2606.13175>
- [58] Farrag, S. E. The Productivity-Reliability Paradox: Specification-Driven Governance for AI-Augmented Software Development. arXiv:2605.01160, 2026-05-01. <https://arxiv.org/abs/2605.01160>