



Contoso Engineering (illustrative mock)

Roadmap AI-SDLC G1

Direção, pessoas e valor

DATA DO ASSESSMENT	2026-09-27
VERSÃO DO FRAMEWORK	2.0.2
RESPONDENTES	14
GERADO EM	2026-09-29

G1: Direção, pessoas e valor

ID	DIMENSÃO	SCORE	NÍVEL	ALVO	GAP	PRIORIDADE	HORIZONTE
D1	Estratégia, política e governança de IA	2,82	L3 Escalando	3,00	0,18	P3 Baixo	Backlog / monitorar
D2	Capacitação, habilidades e cultura	2,28	L2 Adotando	3,00	0,72	P3 Baixo	Backlog / monitorar
D9	Medição, valor e AI FinOps	1,61	L2 Adotando	3,00	1,39	P2 Médio	Semestre

D1: Estratégia, política e governança de IA

DORA identifica uma "postura de IA clara e comunicada" como amplificadora dos benefícios da IA [1], [2]; o Microsoft CAF afirma que "todo agente deve ser observável, governado e seguro" [19].

Comece por aqui

D1-Q5 Níveis de autonomia para trabalho com IA (2,69, L3) não verificado

Meta L3: Uma matriz publicada mapeia tipos de tarefa (por exemplo upgrades de dependências, geração de testes, trabalho de feature, mudanças em produção) para níveis de autonomia e aprovações exigidas.

Depois L4: A matriz é aplicada por regras da plataforma (por exemplo branch protection, revisores exigidos por caminho) e atualizada a partir de dados de incidentes e qualidade. [7][26][32][49][56]

D1-Q6 IA responsável e framework de risco (2,71, L3)

Meta L3: Um framework nomeado é adotado; riscos relacionados a IA estão no registro de riscos com responsáveis e revisões.

Depois L4: Controles do framework são auditados interna ou externamente; resultados retroalimentam política e tooling. [20][21][41][42]

D1-Q3 Ferramentas e modelos aprovados (2,75, L3) não verificado

Meta L3: Políticas enterprise/da organização habilitam apenas recursos e modelos aprovados; o catálogo lista responsável, tratamento de dados e data de revisão para cada ferramenta.

Depois L4: Novos modelos e ferramentas passam por uma avaliação definida por tipo de tarefa (qualidade, custo, segurança) antes da habilitação; os descontinuados são removidos conforme cronograma. [2][15][32][49]

Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S6 Agentic Activation (P2 Médio, Semestre)
- S7 Security & Governance (P2 Médio, Semestre)

Todas as perguntas desta dimensão

ID	PERGUNTA	SCORE	N	NA	EVIDÊNCIAS
D1-Q1	Estratégia de IA para engenharia de software não verificado	2,77	13	1	5
D1-Q2	Política de uso aceitável	2,93	14	0	7
D1-Q3	Ferramentas e modelos aprovados não verificado	2,75	12	2	2
D1-Q4	Proteção de dados, IP e residência não verificado	3,08	13	1	5
D1-Q5	Níveis de autonomia para trabalho com IA não verificado	2,69	13	1	5
D1-Q6	IA responsável e framework de risco	2,71	14	0	7
D1-Q7	Registro e identidade de agentes não verificado	2,79	14	0	5

D2: Capacitação, habilidades e cultura

O Gartner espera que GenAI exija que 80% da força de trabalho de engenharia se requalifique até 2027 [30]; DORA pergunta sobre treinamento, aprendizagem entre pares e suporte à experimentação [2].

Comece por aqui

D2-Q1 Treinamento estruturado de IA (2,15, L2)

Meta L3: Currículo baseado em função (desenvolvedor, revisor, plataforma, segurança) com conclusão rastreada; o treinamento é exigido antes que recursos de agentes sejam habilitados; ensina padrões que preservam o aprendizado (pedir explicações, tentar primeiro, depois comparar) e não apenas delegação total.

Depois L4: O currículo é atualizado a cada trimestre com base em dados de uso e padrões de falha; existem trilhas avançadas (orquestração de agentes, avaliação). [2][30][48]

D2-Q6 Onboarding assistido por IA (2,15, L2)

Meta L3: O onboarding inclui tours de codebase guiados por IA e instruções de repositório; tempo até o primeiro PR mergeado é rastreado; novos engenheiros são avaliados em leitura de code e debugging, não apenas em saída.

Depois L4: Métricas de ramp-up e habilidades são comparadas entre coortes e usadas para melhorar material e instruções de onboarding. [27][48]

D2-Q4 Habilidades de engenharia de contexto (2,21, L2)

Meta L3: Orientações e exemplos sobre engenharia de contexto fazem parte do treinamento; equipes revisam suas instruções e prompts quanto à qualidade.

Depois L4: Práticas de contexto são medidas (por exemplo taxa de sucesso ou uso de tokens por tarefa) e melhoradas ao longo do tempo. [25][30][32]

Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)

Todas as perguntas desta dimensão

ID	PERGUNTA	SCORE	N	NA	EVIDÊNCIAS
D2-Q1	Treinamento estruturado de IA	2,15	13	1	5
D2-Q2	Aprendizagem entre pares e champions	2,36	14	0	6
D2-Q3	Suporte à experimentação	2,57	14	0	7
D2-Q4	Habilidades de engenharia de contexto	2,21	14	0	5
D2-Q5	Papéis e trajetórias de carreira	2,21	14	0	7
D2-Q6	Onboarding assistido por IA	2,15	13	1	5

D9: Medição, valor e AI FinOps

estudos controlados variam de 55.8% mais rápido [33] e 26.08% mais tarefas concluídas [34] a 19% mais lento com uma forte lacuna de percepção [35], portanto as organizações precisam de sua própria medição objetiva; o Gartner prevê que os custos de AI coding ultrapassarão o salário médio de um desenvolvedor até 2028 [32].

Comece por aqui

D9-Q3 Métricas de fluxo de pull request (1,33, L1)

- Meta L3:** Métricas de ciclo de vida de PR são reportadas por organização; PRs criados por agentes são identificados separadamente, incluindo sua taxa de correções pós-merge.
- Depois L4:** Métricas de fluxo são vinculadas a métricas de qualidade (D5) para que fluxo mais rápido não seja comprado com instabilidade. [6][34][50]

D9-Q7 Vínculo com valor de negócio (1,54, L1)

- Meta L3:** Existe um business case com premissas explícitas e ele é revisado pelo menos anualmente.
- Depois L4:** Valor é reportado em uma cadência fixa com insumos medidos de D9-Q1 a Q6; investimento é ajustado a partir dos resultados. [18][28][32]

D9-Q4 Developer experience e fricção (1,57, L1)

- Meta L3:** Uma pesquisa ocorre pelo menos duas vezes por ano com boa participação; resultados são compartilhados e geram ações.
- Depois L4:** Resultados de pesquisa são combinados com telemetria (D9-Q1 a Q3) para encontrar e remover fricção. [2][44]

Estratégias recomendadas

- S2 Foundry + SRE (P1 Alto, Próximo trimestre)
- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)

Todas as perguntas desta dimensão

ID	PERGUNTA	SCORE	N	NA	EVIDÊNCIAS
D9-Q1	Métricas de profundidade de adoção	1,79	14	0	7
D9-Q2	Métricas de resultado de entrega	1,61	13	1	6
D9-Q3	Métricas de fluxo de pull request	1,33	12	2	3
D9-Q4	Developer experience e fricção	1,57	14	0	7
D9-Q5	Medição controlada de impacto	1,64	14	0	8
D9-Q6	Governança de custos de IA (AI FinOps)	1,79	14	0	7
D9-Q7	Vínculo com valor de negócio	1,54	11	3	5

Referências

- [2] DORA. DORA AI Capabilities Model: Survey Questions. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/questions/>
- [6] GitHub Docs. GitHub Copilot usage metrics. <https://docs.github.com/en/copilot/concepts/billing-and-usage/copilot-usage-metrics/copilot-metrics>
- [7] GitHub Docs. Risks and mitigations for GitHub Copilot cloud agent. <https://docs.github.com/en/enterprise-cloud/latest/copilot/concepts/security-governance-and-network-settings/risks-and-mitigations>
- [15] GitHub Docs. Managing policies and features for GitHub Copilot in your organization. <https://docs.github.com/en/copilot/how-tos/administer-copilot/manage-for-organization/manage-policies>
- [18] Microsoft Learn. AI strategy: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/strategy>
- [20] Microsoft Learn. Responsible AI policies: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/responsible-ai-policies>
- [21] Microsoft. Responsible AI Principles and Approach. <https://www.microsoft.com/en-us/ai/principles-and-approach>
- [25] Anthropic. Effective context engineering for AI agents. 2025-09-29. <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
- [26] Anthropic. Building effective agents. 2024-12-19. <https://www.anthropic.com/engineering/building-effective-agents>
- [27] Anthropic. Best practices for Claude Code. Claude Code Docs. <https://code.claude.com/docs/en/best-practices>
- [28] Gartner. Gartner Says 75% of Enterprise Software Engineers Will Use AI Code Assistants by 2028. 2024-04-11. <https://www.gartner.com/en/newsroom/press-releases/2024-04-11-gartner-says-75-percent-of-enterprise-software-engineers-will-use-ai-code-assistants-by-2028>
- [30] Gartner. Gartner Says Generative AI will Require 80% of Engineering Workforce to Upskill Through 2027. 2024-10-03. <https://www.gartner.com/en/newsroom/press-releases/2024-10-03-gartner-says-generative-ai-will-require-80-percent-of-engineering-workforce-to-upskill-through-2027>
- [32] Gartner. Gartner Predicts AI Coding Costs Will Surpass Average Developer's Salary by 2028 as Token Consumption Surges. 2026-06-24. <https://www.gartner.com/en/newsroom/press-releases/2026-06-24-gartner-predicts-ai-coding-costs-will-surpass-average-developer-salary-by-2028-as-token-consumption-surges>
- [34] Cui, Z. K., Demirer, M., Jaffe, S., Musolff, L., Peng, S., Salz, T. The Effects of Generative AI on High-Skilled Work: Evidence from Three Field Experiments with Software Developers. Management Science, published online 2026-02-27. <https://doi.org/10.1287/mnsc.2025.00535> (pre-print: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4945566)
- [41] NIST. AI Risk Management Framework. <https://www.nist.gov/itl/ai-risk-management-framework>
- [42] ISO. ISO/IEC 42001:2023: AI management systems. <https://www.iso.org/standard/42001>
- [44] Forsgren, N., Storey, M.-A., Maddila, C., Zimmermann, T., Houck, B., Butler, J. The SPACE of Developer Productivity. ACM Queue 19(1), 2021-03-06. <https://queue.acm.org/detail.cfm?id=3454124> (DOI: <https://doi.org/10.1145/3454122.3454124>)
- [48] Shen, J. H., Tamkin, A. How AI Impacts Skill Formation. arXiv:2601.20245, 2026-01-28. <https://arxiv.org/abs/2601.20245> (Anthropic summary: <https://www.anthropic.com/research/AI-assistance-coding-skills>)
- [49] Pinna, G., Gong, J., Williams, D., Sarro, F. Comparing AI Coding Agents: A Task-Stratified Analysis of Pull Request Acceptance. arXiv:2602.08915, 2026-02-09. <https://arxiv.org/abs/2602.08915>
- [50] Takerngsaksiri, W., Duong, N., Barnett, S. Who Finishes the Job? A Study of Follow-Up Fixes and Commit Authorship on AI Coding Agent Pull Requests. arXiv:2609.26847, 2026-09-22. <https://arxiv.org/abs/2609.26847>
- [56] Monperrus, M. The End of Code Review: Coding Agents Supersede Human Inspection. arXiv:2606.13175, 2026-06-11. <https://arxiv.org/abs/2606.13175>