




Contoso Engineering (illustrative mock)

Guía de implementación

De la evaluación a la ejecución: gobierno, plan por fases, gestión del cambio y los primeros 90 días

FECHA DEL ASSESSMENT	2026-09-27
VERSIÓN DEL FRAMEWORK	2.0.1
PERSONAS QUE RESPONDIERON	14
GENERADO EL	2026-09-28

1. Resumen ejecutivo



Contoso Engineering (illustrative mock) obtuvo 2,04 (L2 Adoptando) con 14 personas encuestadas. 9 de 9 dimensiones están bajo el objetivo de 3,0. El plan ordena el trabajo por prioridad (peso × brecha) y empieza por las preguntas de menor puntaje de cada dimensión; cada ítem termina cuando se cumple su ancla L3 y se confirma con evidencias.

1.1 Atender antes de comprometer objetivos

Fundamentos débiles: D8
Brecha de percepción: D1, D2, D3, D5, D6, D7, D8, D9
Baja confianza: D6
Fortalezas no verificadas: D1-Q1, D1-Q3, D1-Q4, D1-Q5, D1-Q7, D4-Q1, D4-Q3, D4-Q4, D4-Q5, D4-Q6, D4-Q7
Telemetría bajo las respuestas: D4-Q1

No se encontró implementation-guide-inputs.json. Las secciones de gobierno, gestión del cambio y registro de riesgos muestran qué completar; usa wizard/implementation-guide-wizard.html.

2. Gobierno

2.1 Comité directivo

Patrocina el programa, aprueba objetivos e inversión y elimina bloqueos.

A completar con el cliente

2.2 Oficina del programa

Conduce el plan semana a semana, mantiene el backlog e informa el avance al comité directivo.

A completar con el cliente

2.3 Responsables por dimensión

Una persona responsable (accountable) por cada dimensión bajo el objetivo.

ID	DIMENSIÓN	PRIORIDAD	HORIZONTE	RESPONSABLE
D1	Estrategia, política y gobernanza de IA	P3 Bajo	Backlog / monitorear	A completar con el cliente
D2	Habilitación, habilidades y cultura	P3 Bajo	Backlog / monitorear	A completar con el cliente
D3	Planificar, especificar y diseñar	P2 Medio	Semestre	A completar con el cliente
D4	Código e ingeniería de contexto	P3 Bajo	Backlog / monitorear	A completar con el cliente
D5	Revisión, calidad y pruebas	P2 Medio	Semestre	A completar con el cliente
D6	Seguridad y cadena de suministro de IA	P2 Medio	Semestre	A completar con el cliente
D7	Entregar y operar	P2 Medio	Semestre	A completar con el cliente
D8	Fundamentos de ingeniería (amplificadores de IA)	P1 Alto	Próximo trimestre	A completar con el cliente
D9	Medición, valor y AI FinOps	P2 Medio	Semestre	A completar con el cliente

2.4 RACI

A completar con el cliente

3. Plan por fases

Cada dimensión bajo el objetivo queda en el horizonte dado por su prioridad: P0 en 30 días, P1 el próximo trimestre, P2 en el semestre, P3 en el backlog. Empieza por las preguntas listadas; un ítem termina cuando se cumple su ancla L3 y las evidencias listadas lo confirman.

3.1 P1: Próximo trimestre

D8: Fundamentos de ingeniería (amplificadores de IA) (1,09 → 3,0, P1 Alto)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D8-Q7	Pruebas automatizadas como sistema de control KPI: % de servicios que cumplen el ancla L3	0,75	La mayoría de los servicios tiene pruebas automatizadas por capas que se ejecutan en cada PR dentro de time budgets acordados. [3]	Inventario de suites de prueba, duraciones de pipeline, datos de defectos escapados.
D8-Q4	Ecosistema de datos saludable KPI: Nivel de la práctica en toda la organización	0,92	Los datos clave están catalogados con responsables e indicadores de calidad; la mayoría de las preguntas puede responderse en una hora. [1][2]	Catálogo de datos, dashboards de calidad.
D8-Q5	Entornos reproducibles para humanos y agentes KPI: % de repositorios que cumplen el ancla L3	1,00	La mayoría de los repositorios define un entorno reproducible; los agentes usan la misma definición. [8]	Archivos devcontainer, tiempos de start-up de entorno.

Estrategias de este horizonte

- **S2 Foundry + SRE, S3 App Modernization, S1 GitHub Migration:** Empiece por D8-Q7 (Pruebas automatizadas como sistema de control). Meta del ancla L3: La mayoría de los servicios tiene pruebas automatizadas por capas que se ejecutan en cada PR dentro de time budgets acordados.

3.2 P2: Semestre

D3: Planificar, especificar y diseñar (2,09 → 3,0, P2 Medio)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D3-Q1	IA en refinamiento de backlog KPI: % de equipos que cumplen el ancla L3	2,00	La mayoría de los equipos usa IA para redactar o mejorar elementos de trabajo; los criterios de aceptación son obligatorios antes de comenzar el trabajo. [16][17]	Templates de issue, ejemplos de elementos de trabajo, verificaciones de calidad.
D3-Q2	Especificación antes de la implementación KPI: % de equipos que cumplen el ancla L3	2,00	Los planes o specs se almacenan en el repositorio o se vinculan a la issue, y un humano los revisa antes de la implementación por el agente. [23][24][27][58]	Archivos de spec, reviews de plan, PRs que referencian specs.
D3-Q5	Enfoque centrado en el usuario KPI: % de equipos que cumplen el ancla L3	2,07	Los elementos de trabajo referencian el problema del usuario y la medida de éxito; el feedback se revisa antes de priorizar. [1][2][3]	Briefs de producto, registros de loop de feedback, dashboards de resultados.

D5: Revisión, calidad y pruebas (2,10 → 3,0, P2 Medio)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D5-Q6	Cultura de verificación y confianza calibrada KPI: % de equipos que cumplen el ancla L3	1,77	Las directrices de review explican qué verificar en la salida de IA; la confianza en la salida de IA es parte de la encuesta a desarrolladores. [3][23][35][37][48][52]	Directrices de review, resultados de encuesta, análisis de defectos.
D5-Q3	Mismos quality gates para code de IA y humano KPI: % de repositorios que cumplen el ancla L3	2,00	Los checks requeridos se aplican mediante rulesets en los protected branches de la mayoría de los repositorios, sin bypass para identidades de agentes. [3][7][31][50][55]	Rulesets, checks requeridos, listas de bypass.
D5-Q1	AI-assisted code review KPI: % de repositorios que cumplen el ancla L3	2,07	AI review se ejecuta automáticamente en la mayoría de los PRs; los equipos rastrean sugerencias útiles versus descartadas. [6][12][14][54][55]	Rulesets de repositorio, métricas de adopción de code review, resultados de sugerencias.

D6: Seguridad y cadena de suministro de IA (1,90 → 3,0, P2 Medio)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D6-Q5	AI supply chain KPI: % de repositorios que cumplen el ancla L3	1,50	Un proceso de review cubre componentes de IA; SBOMs y procedencia de build se producen para la mayoría de los builds. [38][40][43][52]	Registros de review de componentes, muestras de SBOM y atestación.
D6-Q6	Threat modeling para features y agentes de IA KPI: % de servicios que cumplen el ancla L3	1,62	Se requieren threat models para nuevas features de IA y workflows de agentes, y seguridad los revisa. [38][39][40]	Documentos de threat model, registros de security review.
D6-Q4	Least privilege para agentes KPI: Nivel de la práctica en toda la organización	1,71	Los permisos de agentes se documentan y revisan; los agentes no pueden acceder a credenciales de producción ni hacer push a protected branches. [7][19][38][39]	Configuración de entorno de agentes, alcances de token, revisiones de acceso.

D7: Entregar y operar (1,75 → 3,0, P2 Medio)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D7-Q4	Observabilidad de agentes KPI: Nivel de la práctica en toda la organización	1,57	Los runs de agentes emiten telemetría al stack central de observabilidad; los dashboards muestran fallas y costo por agente. [19][32][45]	Dashboards de telemetría, reglas de alerta.
D7-Q1	IA en pipelines CI/CD KPI: % de repositorios que cumplen el ancla L3	1,69	Los pipelines son code en la mayoría de los repositorios; el análisis de fallas asistido por IA está disponible para todos los equipos. [16][17]	Repositorios de pipeline, uso de análisis de fallas, métricas de build.
D7-Q3	Respuesta a incidentes asistida por IA KPI: % de servicios que cumplen el ancla L3	1,71	Los ingenieros de on-call en la mayoría de los equipos usan IA para triage y resúmenes; las revisiones post-incidente registran si la IA ayudó. [16][17][22]	Configuración de herramientas de incidentes, timelines de incidentes, datos de tiempo de restauración.

D9: Medición, valor y AI FinOps (1,61 → 3,0, P2 Medio)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D9-Q3	Métricas de flujo de pull request KPI: Nivel de la práctica en toda la organización	1,33	Las métricas de ciclo de vida de PR se reportan por organización; los PRs creados por agentes se identifican por separado, incluida su tasa de correcciones post-merge. [6][34][50]	Métricas de ciclo de vida de PR, informes de PRs de agentes, análisis de correcciones de seguimiento.
D9-Q7	Vínculo con valor de negocio KPI: Nivel de la práctica en toda la organización	1,54	Existe un business case con supuestos explícitos y se revisa al menos anualmente. [18][28][32]	Business case, informes de valor.
D9-Q4	Developer experience y fricción KPI: Nivel de la práctica en toda la organización	1,57	Una encuesta se realiza al menos dos veces al año con buena participación; los resultados se comparten y generan acciones. [2][44]	Instrumento de encuesta, tasa de participación, log de acciones.

Estrategias de este horizonte

- **S5 GitHub Copilot Acceleration:** Empiece por D9-Q3 (Métricas de flujo de pull request).
Meta del ancla L3: Las métricas de ciclo de vida de PR se reportan por organización; los PRs creados por agentes se identifican por separado, incluida su tasa de correcciones post-merge.
- **S6 Agentic Activation, S7 Security & Governance:** Empiece por D6-Q5 (AI supply chain).
Meta del ancla L3: Un proceso de review cubre componentes de IA; SBOMs y procedencia de build se producen para la mayoría de los builds.

3.3 P3: Backlog / monitorear

D1: Estrategia, política y gobernanza de IA (2,82 → 3,0, P3 Bajo)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D1-Q5	Niveles de autonomía para trabajo con IA no verificado KPI: Nivel de la práctica en toda la organización	2,69	Una matriz publicada mapea tipos de tarea (por ejemplo upgrades de dependencias, generación de pruebas, trabajo de feature, cambios en producción) a niveles de autonomía y aprobaciones requeridas. [7][26][32][49][56]	Matriz de autonomía, rulesets de repositorio, registros de cambios.
D1-Q6	IA responsable y framework de riesgo KPI: Nivel de la práctica en toda la organización	2,71	Se adopta un framework nombrado; los riesgos relacionados con IA están en el registro de riesgos con responsables y revisiones. [20][21][41][42]	Mapeo del framework, entradas del registro de riesgos, informes de auditoría.
D1-Q3	Herramientas y modelos aprobados no verificado KPI: Nivel de la práctica en toda la organización	2,75	Las políticas enterprise/de la organización habilitan solo funciones y modelos aprobados; el catálogo lista responsable, manejo de datos y fecha de revisión para cada herramienta. [2][15][32][49]	Configuraciones de política de Copilot, catálogo de herramientas, registros de evaluación de modelos.

D2: Habilitación, habilidades y cultura (2,28 → 3,0, P3 Bajo)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D2-Q1	Capacitación estructurada de IA KPI: % de ingenieros que cumplen el ancla L3	2,15	Currículo basado en rol (desarrollador, revisor, plataforma, seguridad) con finalización rastreada; la capacitación se exige antes de habilitar funciones de agentes; enseña patrones que preservan el aprendizaje (pedir explicaciones, intentar primero, luego comparar) y no solo delegación total. [2][30][48]	Rutas de aprendizaje, tasas de finalización, reglas de bloqueo de habilitación.
D2-Q6	Onboarding asistido por IA KPI: % de ingenieros que cumplen el ancla L3	2,15	El onboarding incluye recorridos de codebase guiados por IA e instrucciones de repositorio; se rastrea el tiempo hasta el primer PR mergeado; los nuevos ingenieros son evaluados en lectura de code y debugging, no solo en salida. [27][48]	Playbook de onboarding, datos de tiempo hasta primer PR, resultados de verificación de habilidades.
D2-Q4	Habilidades de ingeniería de contexto KPI: % de ingenieros que cumplen el ancla L3	2,21	La orientación y los ejemplos sobre ingeniería de contexto son parte de la capacitación; los equipos revisan la calidad de sus instrucciones y prompts. [25][30][32]	Páginas de orientación, checklists de review, métricas antes/después.

D4: Código e ingeniería de contexto (2,72 → 3,0, P3 Bajo)

ID	PREGUNTA	PUNTAJE	LISTO CUANDO (ANCLA L3)	EVIDENCIAS A REUNIR
D4-Q4	Instrucciones de repositorio no verificado KPI: % de repositorios que cumplen el ancla L3	2,50	La mayoría de los repositorios activos tiene instrucciones estructuradas (build, test, convenciones, restricciones) con un responsable; los cambios pasan por PR review; los archivos se actualizan cuando el codebase cambia en vez de commitarlos una sola vez. [2][8][25][27][46][47][55]	Archivos de instrucciones, cobertura entre repositorios, historial de cambios, métricas antes/después de PRs de agentes.
D4-Q1	Profundidad de uso de IA entre superficies no verificado KPI: % de ingenieros que cumplen el ancla L3	2,62	Muchos ingenieros usan regularmente al menos una superficie de agente de GitHub ("Agent first"), confirmado por métricas de uso. [6]	Dashboard o API de métricas de uso de Copilot: distribución de cohortes de adopción, usuarios activos diarios/semanales.
D4-Q2	Modo agente para trabajo multi-file KPI: % de ingenieros que cumplen el ancla L3	2,64	Agent mode es el valor predeterminado para refactors y features multi-file en la mayoría de los equipos; los cambios se revisan en el diff antes del commit. [6][27]	Uso por feature/mode, directrices del equipo.

4. Gestión del cambio

4.1 Plan ADKAR

Conciencia, Deseo, Conocimiento, Habilidad y Refuerzo: las intervenciones planificadas para cada etapa.

A completar con el cliente

4.2 Plan de comunicación

A completar con el cliente

4.3 Plan de capacitación

D2 Habilidad, habilidades y cultura obtuvo 2,28 (L2 Adoptando). Arma los grupos de capacitación a partir del Learning and Growth Survey (/plano-capacitacao) y dales seguimiento en D2.

A completar con el cliente

5. Riesgos

Riesgos señalados por las reglas de puntaje y, luego, el registro de riesgos del propio cliente.

RIESGO	AFECTA	MITIGACIÓN
Fundamentos débiles Las dimensiones amplificadoras están al menos una banda bajo el nivel general. DORA concluye que la IA amplifica las fortalezas y debilidades existentes [3].	D8	Eleva estas dimensiones antes de escalar la adopción de IA.
Brecha de percepción Los ejecutivos califican estas dimensiones al menos una banda por encima de los ingenieros hands-on.	D1, D2, D3, D5, D6, D7, D8, D9	Revisa la brecha con ambos grupos y confirma con telemetría y evidencias antes de fijar objetivos.
Baja confianza Más del 30% de las respuestas son NA en estas dimensiones.	D6	Busca personas que conozcan estas prácticas y vuelve a preguntar.
Fortalezas no verificadas Puntaje L3 o mayor, pero menos de la mitad de las respuestas trae evidencias.	D1-Q1, D1-Q3, D1-Q4, D1-Q5, D1-Q7, D4-Q1, D4-Q3, D4-Q4, D4-Q5, D4-Q6, D4-Q7	Confirma con evidencias antes de presentar estas preguntas como fortalezas.
Telemetría bajo las respuestas Las métricas de uso de Copilot sostienen un nivel de D4-Q1 menor que el de las respuestas.	D4-Q1	Revisa D4-Q1 con la telemetría y define metas de adopción a partir de ella.

5.1 Registro de riesgos del cliente

A completar con el cliente

6. Métricas de éxito y reevaluación

Puntaje actual y objetivo de cada dimensión bajo el objetivo. El KPI de cada ítem está en el plan por fases.

ID	DIMENSIÓN	PUNTAJE	OBJETIVO	BRECHA	HORIZONTE
D1	Estrategia, política y gobernanza de IA	2,82	3,0	0,18	Backlog / monitorear
D2	Habilitación, habilidades y cultura	2,28	3,0	0,72	Backlog / monitorear
D3	Planificar, especificar y diseñar	2,09	3,0	0,91	Semestre
D4	Código e ingeniería de contexto	2,72	3,0	0,28	Backlog / monitorear
D5	Revisión, calidad y pruebas	2,10	3,0	0,90	Semestre
D6	Seguridad y cadena de suministro de IA	1,90	3,0	1,10	Semestre
D7	Entregar y operar	1,75	3,0	1,25	Semestre
D8	Fundamentos de ingeniería (amplificadores de IA)	1,09	3,0	1,91	Próximo trimestre
D9	Medición, valor y AI FinOps	1,61	3,0	1,39	Semestre

- Reevalúa al final de cada horizonte con el mismo formulario y compara las rondas con make compare BEFORE=... AFTER=... (el PDF de comparación muestra las variaciones).
- Cuando exista, confirma D4 y D9 con las métricas de uso de Copilot [6] y métricas de entrega (D9-Q2) antes de informar avances.

7. Primeros 90 días

Sugeridos a partir de los resultados de la evaluación. Confírmalos o reemplázalos con el cliente en el wizard.

7.1 Semanas 1 a 4

- Define una persona responsable y reúne las evidencias actuales de D8-Q7 (Pruebas automatizadas como sistema de control).
- Define una persona responsable y reúne las evidencias actuales de D8-Q4 (Ecosistema de datos saludable).
- Define una persona responsable y reúne las evidencias actuales de D8-Q5 (Entornos reproducibles para humanos y agentes).

7.2 Semanas 5 a 8

- Iniciar S2 Foundry + SRE: Empiece por D8-Q7 (Pruebas automatizadas como sistema de control). Meta del ancla L3: La mayoría de los servicios tiene pruebas automatizadas por capas que se ejecutan en cada PR dentro de time budgets acordados.
- Iniciar S5 GitHub Copilot Acceleration: Empiece por D9-Q3 (Métricas de flujo de pull request). Meta del ancla L3: Las métricas de ciclo de vida de PR se reportan por organización; los PRs creados por agentes se identifican por separado, incluida su tasa de correcciones post-merge.

7.3 Semanas 9 a 12

- Verifica D1, D2, D3, D4 contra sus anclas L3 con evidencias y planifica el siguiente horizonte.

8. Referencias

- [1] DORA. DORA AI Capabilities Model. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/report/>
- [2] DORA. DORA AI Capabilities Model: Survey Questions. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/questions/>
- [3] Google Cloud. Announcing the 2025 DORA Report: State of AI-Assisted Software Development. 2025. <https://cloud.google.com/blog/products/ai-machine-learning/announcing-the-2025-dora-report>
- [6] GitHub Docs. GitHub Copilot usage metrics. <https://docs.github.com/en/copilot/concepts/billing-and-usage/copilot-usage-metrics/copilot-metrics>
- [7] GitHub Docs. Risks and mitigations for GitHub Copilot cloud agent. <https://docs.github.com/en/enterprise-cloud@latest/copilot/concepts/security-governance-and-network-settings/risks-and-mitigations>
- [8] GitHub Docs. Best practices for using GitHub Copilot to work on tasks. <https://docs.github.com/en/enterprise-cloud@latest/copilot/tutorials/cloud-agent/get-the-best-results>
- [12] GitHub Docs. About GitHub Copilot code review. <https://docs.github.com/copilot/concepts/agents/code-review>
- [14] GitHub Docs. Application card: GitHub Copilot Agents. <https://docs.github.com/en/copilot/responsible-use/agents>
- [15] GitHub Docs. Managing policies and features for GitHub Copilot in your organization. <https://docs.github.com/en/copilot/how-tos/administer-copilot/manage-for-organization/manage-policies>
- [16] Microsoft Azure Blog. Agentic DevOps: Evolving software development with GitHub Copilot and Microsoft Azure. 2025. <https://azure.microsoft.com/en-us/blog/agentic-devops-evolving-software-development-with-github-copilot-and-microsoft-azure/>
- [17] Microsoft for Developers. Agentic DevOps in action: Reimagining every phase of the developer lifecycle. 2025. <https://developer.microsoft.com/blog/reimagining-every-phase-of-the-developer-lifecycle/>
- [18] Microsoft Learn. AI strategy: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/strategy>
- [19] Microsoft Learn. Govern and secure AI agents: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai-agents/governance-security-across-organization>
- [20] Microsoft Learn. Responsible AI policies: Cloud Adoption Framework. <https://learn.microsoft.com/en-us/azure/cloud-adoption-framework/ai/responsible-ai-policies>
- [21] Microsoft. Responsible AI Principles and Approach. <https://www.microsoft.com/en-us/ai/principles-and-approach>
- [22] Microsoft Azure Blog. Announcing Azure Copilot agents and AI infrastructure innovations. 2025. <https://azure.microsoft.com/en-us/blog/announcing-azure-copilot-agents-and-ai-infrastructure-innovations/>
- [23] Anthropic. Anthropic Economic Index: AI's impact on software development. 2025-04-28. <https://www.anthropic.com/research/impact-software-development>
- [24] Anthropic. How Claude Code is used in practice. 2026-06-16. <https://www.anthropic.com/research/claude-code-expertise>
- [25] Anthropic. Effective context engineering for AI agents. 2025-09-29. <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
- [26] Anthropic. Building effective agents. 2024-12-19. <https://www.anthropic.com/engineering/building-effective-agents>
- [27] Anthropic. Best practices for Claude Code. Claude Code Docs. <https://code.claude.com/docs/en/best-practices>
- [28] Gartner. Gartner Says 75% of Enterprise Software Engineers Will Use AI Code Assistants by 2028. 2024-04-11. <https://www.gartner.com/en/newsroom/press-releases/2024-04-11-gartner-says-75-percent-of-enterprise-software-engineers-will-use-ai-code-assistants-by-2028>
- [30] Gartner. Gartner Says Generative AI will Require 80% of Engineering Workforce to Upskill Through 2027. 2024-10-03. <https://www.gartner.com/en/newsroom/press-releases/2024-10-03-gartner-says-generative-ai-will-require-80-percent-of-engineering-workforce-to-upskill-through-2027>

- [31] Gartner. Gartner Says the Market for Enterprise AI Coding Agents Is Entering a New Phase of Expansion and Competitive Realignment. 2026-05-20. <https://www.gartner.com/en/newsroom/press-releases/2026-05-20-gartner-says-the-market-for-enterprise-ai-coding-agents-is-entering-a-new-phase-of-expansion-and-competitive-realignment>
- [32] Gartner. Gartner Predicts AI Coding Costs Will Surpass Average Developer's Salary by 2028 as Token Consumption Surges. 2026-06-24. <https://www.gartner.com/en/newsroom/press-releases/2026-06-24-gartner-predicts-ai-coding-costs-will-surpass-average-developer-salary-by-2028-as-token-consumption-surges>
- [34] Cui, Z. K., Demirer, M., Jaffe, S., Musolff, L., Peng, S., Salz, T. The Effects of Generative AI on High-Skilled Work: Evidence from Three Field Experiments with Software Developers. Management Science, published online 2026-02-27. <https://doi.org/10.1287/mnsc.2025.00535> (pre-print: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4945566)
- [35] METR. Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity. 2025-07-10. <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/> (paper: <https://arxiv.org/abs/2507.09089>)
- [37] Stack Overflow. 2025 Developer Survey: AI. <https://survey.stackoverflow.co/2025/ai>
- [38] OWASP GenAI Security Project. OWASP Top 10 for LLM Applications 2025. <https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/>
- [39] OWASP GenAI Security Project. OWASP Top 10 for Agentic Applications for 2026. 2025-12-09. <https://genai.owasp.org/resource/owasp-top-10-for-agentic-applications-for-2026/>
- [40] NIST. SP 800-218A: Secure Software Development Practices for Generative AI and Dual-Use Foundation Models: An SSDF Community Profile. 2024-07. <https://csrc.nist.gov/pubs/sp/800/218/a/final>
- [41] NIST. AI Risk Management Framework. <https://www.nist.gov/itl/ai-risk-management-framework>
- [42] ISO. ISO/IEC 42001:2023: AI management systems. <https://www.iso.org/standard/42001>
- [43] OpenSSF. SLSA: Supply-chain Levels for Software Artifacts. <https://slsa.dev/>
- [44] Forsgren, N., Storey, M.-A., Maddila, C., Zimmermann, T., Houck, B., Butler, J. The SPACE of Developer Productivity. ACM Queue 19(1), 2021-03-06. <https://queue.acm.org/detail.cfm?id=3454124> (DOI: <https://doi.org/10.1145/3454122.3454124>)
- [45] Liu, B., Qiu, H., Goiri, Í., Fonseca, R., Bianchini, R., Choukse, E. Agentic Coding in the Wild: Characterizing GitHub Copilot Traces at Production Scale. arXiv:2608.00101, 2026-07-30. <https://arxiv.org/abs/2608.00101>
- [46] Arabat, A., Sayagh, M. Toward Instructions-as-Code: Understanding the Impact of Instruction Files on Agentic Pull Requests. arXiv:2606.13449, 2026-06-11. <https://arxiv.org/abs/2606.13449>
- [47] Denisov-Blanch, Y., Agarwal, S., Azaletskiy, P., He, H., Schaeffer, R., Miranda, B., Vasilescu, B., Koyejo, S. A Few Pages of Markdown: Committed AI Configuration and Lower Quality Cost after Coding-Agent Adoption. arXiv:2608.25241, 2026-08-26. <https://arxiv.org/abs/2608.25241>
- [48] Shen, J. H., Tamkin, A. How AI Impacts Skill Formation. arXiv:2601.20245, 2026-01-28. <https://arxiv.org/abs/2601.20245> (Anthropic summary: <https://www.anthropic.com/research/AI-assistance-coding-skills>)
- [49] Pinna, G., Gong, J., Williams, D., Sarro, F. Comparing AI Coding Agents: A Task-Stratified Analysis of Pull Request Acceptance. arXiv:2602.08915, 2026-02-09. <https://arxiv.org/abs/2602.08915>
- [50] Takerngsaksiri, W., Duong, N., Barnett, S. Who Finishes the Job? A Study of Follow-Up Fixes and Commit Authorship on AI Coding Agent Pull Requests. arXiv:2609.26847, 2026-09-22. <https://arxiv.org/abs/2609.26847>
- [52] Sakib, A. H. M. N., Banik, D., Jadhwal, M. Trust but Verify? Uncovering the Security Debt of Autonomous Coding Agents. arXiv:2607.12428, 2026-07-14. <https://arxiv.org/abs/2607.12428>
- [54] Selvanayagam, N., Ghaleb, T. A. AI-to-AI Code Reviews of GitHub Pull Requests. arXiv:2608.21311, 2026-08-21. <https://arxiv.org/abs/2608.21311>
- [55] Stolze, M., Strässle, M. When Review Alone No Longer Scales: Layered Supervision in AI-Assisted Software Engineering. arXiv:2608.26316, 2026-08-26. <https://arxiv.org/abs/2608.26316>
- [56] Monperrus, M. The End of Code Review: Coding Agents Supersede Human Inspection. arXiv:2606.13175, 2026-06-11. <https://arxiv.org/abs/2606.13175>
- [58] Farrag, S. E. The Productivity-Reliability Paradox: Specification-Driven Governance for AI-Augmented Software Development. arXiv:2605.01160, 2026-05-01. <https://arxiv.org/abs/2605.01160>