



Contoso Engineering (illustrative mock)

# Roadmap AI-SDLC G2

Planejar, construir e revisar

|                     |            |
|---------------------|------------|
| DATA DO ASSESSMENT  | 2026-09-27 |
| VERSÃO DO FRAMEWORK | 2.0.1      |
| RESPONDENTES        | 14         |
| GERADO EM           | 2026-09-28 |

## G2: Planejar, construir e revisar

| ID | DIMENSÃO                         | SCORE | NÍVEL        | ALVO | GAP  | PRIORIDADE | HORIZONTE           |
|----|----------------------------------|-------|--------------|------|------|------------|---------------------|
| D3 | Planejar, especificar e desenhar | 2,09  | L2 Adotando  | 3,00 | 0,91 | P2 Médio   | Semestre            |
| D4 | Código e engenharia de contexto  | 2,72  | L3 Escalando | 3,00 | 0,28 | P3 Baixo   | Backlog / monitorar |
| D5 | Revisão, qualidade e testes      | 2,10  | L2 Adotando  | 3,00 | 0,90 | P2 Médio   | Semestre            |

## D3: Planejar, especificar e desenhar

em agentic coding, "as pessoas tomam a maior parte das decisões de planejamento (o que fazer) e Claude toma a maior parte das decisões de execução (como fazer)" [24]; a qualidade da definição da tarefa impulsiona a qualidade da saída do agente [8], [27].

### Comece por aqui

#### D3-Q1 IA no refinamento de backlog (2,00, L2)

**Meta L3:** A maioria das equipes usa IA para redigir ou melhorar itens de trabalho; critérios de aceite são obrigatórios antes do trabalho começar.

**Depois L4:** A qualidade dos itens de trabalho (clareza, testabilidade) é medida e vinculada a retrabalho e cycle time. [16][17]

#### D3-Q2 Especificação antes da implementação (2,00, L2)

**Meta L3:** Planos ou specs são armazenados no repositório ou vinculados à issue, e são revisados por um humano antes da implementação pelo agente.

**Depois L4:** Specs são o contrato para verificação automatizada (testes, checks) e são mantidas sincronizadas com o code. [23][24][27][58]

#### D3-Q5 Foco centrado no usuário (2,07, L2)

**Meta L3:** Itens de trabalho referenciam o problema do usuário e a medida de sucesso; feedback é revisado antes da priorização.

**Depois L4:** Métricas de resultado do usuário fazem parte da definition of done para entrega assistida por IA. [1][2][3]

### Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S3 App Modernization (P1 Alto, Próximo trimestre)

### Todas as perguntas desta dimensão

| ID    | PERGUNTA                             | SCORE | N  | NA | EVIDÊNCIAS |
|-------|--------------------------------------|-------|----|----|------------|
| D3-Q1 | IA no refinamento de backlog         | 2,00  | 13 | 1  | 2          |
| D3-Q2 | Especificação antes da implementação | 2,00  | 12 | 2  | 6          |
| D3-Q3 | Escopo de tarefas para agentes       | 2,15  | 13 | 1  | 3          |
| D3-Q4 | Decisões de arquitetura e design     | 2,15  | 13 | 1  | 4          |
| D3-Q5 | Foco centrado no usuário             | 2,07  | 14 | 0  | 4          |
| D3-Q6 | Modernização assistida por IA        | 2,14  | 14 | 0  | 7          |

## D4: Código e engenharia de contexto

GitHub mede a profundidade de adoção como uma progressão de "Code first" para "Agent first" e "Multi-agent" [6]; a Anthropic descreve contexto como "um recurso finito com retornos marginais decrescentes" [25].

### Comece por aqui

#### D4-Q4 Instruções de repositório (2,50, L3) não verificado

- Meta L3:** A maioria dos repositórios ativos tem instruções estruturadas (build, test, convenções, restrições) com um responsável; mudanças passam por PR review; arquivos são atualizados quando o codebase muda, em vez de serem commitados uma vez.
- Depois L4:** Instruções são geradas a partir de uma base compartilhada, verificadas quanto a desatualização, e seu efeito na taxa de merge de agentes e na qualidade de code é medido, já que arquivos de instrução sozinhos não garantem melhores resultados. [2][8][25][27][46][47][55]

#### D4-Q1 Profundidade do uso de IA entre superfícies (2,62, L3) não verificado

- Meta L3:** Muitos engenheiros usam regularmente pelo menos uma superfície de agente do GitHub ("Agent first"), confirmado por métricas de uso.
- Depois L4:** Uso multi-agent é normal ("Multi-agent"), com distribuição de coortes rastreada mensalmente. [6]

#### D4-Q2 Modo agente para trabalho multi-file (2,64, L3)

- Meta L3:** Agent mode é o padrão para refactors e features multi-file na maioria das equipes; mudanças são revisadas no diff antes do commit.
- Depois L4:** Equipes compartilham padrões de agent mode que funcionam e rastreiam onde ele falha; permissões de ferramentas são ajustadas por repositório. [6][27]

### Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S6 Agentic Activation (P2 Médio, Semestre)

### Todas as perguntas desta dimensão

| ID    | PERGUNTA                                                   | SCORE | N  | NA | EVIDÊNCIAS |
|-------|------------------------------------------------------------|-------|----|----|------------|
| D4-Q1 | Profundidade do uso de IA entre superfícies não verificado | 2,62  | 13 | 1  | 5          |
| D4-Q2 | Modo agente para trabalho multi-file                       | 2,64  | 14 | 0  | 7          |
| D4-Q3 | Delegação a coding agents não verificado                   | 2,67  | 12 | 2  | 4          |
| D4-Q4 | Instruções de repositório não verificado                   | 2,50  | 12 | 2  | 5          |
| D4-Q5 | Prompts, agentes e skills reutilizáveis não verificado     | 2,79  | 14 | 0  | 4          |
| D4-Q6 | Governança de MCP servers não verificado                   | 2,79  | 14 | 0  | 5          |
| D4-Q7 | Acesso de IA ao conhecimento interno não verificado        | 3,08  | 12 | 2  | 3          |
| D4-Q8 | Seleção e roteamento de modelos                            | 2,69  | 13 | 1  | 7          |

## D5: Revisão, qualidade e testes

DORA vincula o volume de mudanças impulsionadas por IA à instabilidade, a menos que existam sistemas de controle fortes [3]; GitHub exige revisão humana antes que PRs de agentes sejam mergeados [7]; 46% dos desenvolvedores desconfiam da precisão da saída de IA [37].

### Comece por aqui

#### D5-Q6 Cultura de verificação e confiança calibrada (1,77, L2)

**Meta L3:** Diretrizes de review explicam o que verificar na saída de IA; confiança na saída de IA faz parte da pesquisa com desenvolvedores.

**Depois L4:** Confiança e precisão são comparadas com dados reais de defeitos, e a orientação é atualizada onde divergem. [3][23][35][37][48][52]

#### D5-Q3 Mesmos quality gates para code de IA e humano (2,00, L2)

**Meta L3:** Checks exigidos são aplicados por rulesets nos protected branches da maioria dos repositórios, sem bypass para identidades de agentes.

**Depois L4:** Gates são policy as code, aplicados em todos os repositórios (>90%) e revisados após incidentes. [3][7][31][50][55]

#### D5-Q1 AI-assisted code review (2,07, L2)

**Meta L3:** AI review executa automaticamente na maioria dos PRs; equipes rastreiam sugestões úteis versus descartadas.

**Depois L4:** Regras de review são ajustadas por repositório a partir dos resultados de sugestões; tempo de review e defeitos escapados são rastreados; PRs em que apenas IA revisou code criado por IA são visíveis e governados. [6][12][14][54][55]

### Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S7 Security & Governance (P2 Médio, Semestre)

### Todas as perguntas desta dimensão

| ID    | PERGUNTA                                      | SCORE | N  | NA | EVIDÊNCIAS |
|-------|-----------------------------------------------|-------|----|----|------------|
| D5-Q1 | AI-assisted code review                       | 2,07  | 14 | 0  | 6          |
| D5-Q2 | Human-in-the-loop para mudanças de agentes    | 2,07  | 14 | 0  | 6          |
| D5-Q3 | Mesmos quality gates para code de IA e humano | 2,00  | 13 | 1  | 2          |
| D5-Q4 | Lotes pequenos                                | 2,17  | 12 | 2  | 7          |
| D5-Q5 | Testes assistidos por IA                      | 2,31  | 13 | 1  | 2          |
| D5-Q6 | Cultura de verificação e confiança calibrada  | 1,77  | 13 | 1  | 8          |
| D5-Q7 | Saúde do code gerado por IA                   | 2,29  | 14 | 0  | 2          |

## Referências

---

- [1] DORA. DORA AI Capabilities Model. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/report/>
- [2] DORA. DORA AI Capabilities Model: Survey Questions. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/questions/>
- [3] Google Cloud. Announcing the 2025 DORA Report: State of AI-Assisted Software Development. 2025. <https://cloud.google.com/blog/products/ai-machine-learning/announcing-the-2025-dora-report>
- [6] GitHub Docs. GitHub Copilot usage metrics. <https://docs.github.com/en/copilot/concepts/billing-and-usage/copilot-usage-metrics/copilot-metrics>
- [7] GitHub Docs. Risks and mitigations for GitHub Copilot cloud agent. <https://docs.github.com/en/enterprise-cloud@latest/copilot/concepts/security-governance-and-network-settings/risks-and-mitigations>
- [8] GitHub Docs. Best practices for using GitHub Copilot to work on tasks. <https://docs.github.com/en/enterprise-cloud@latest/copilot/tutorials/cloud-agent/get-the-best-results>
- [12] GitHub Docs. About GitHub Copilot code review. <https://docs.github.com/copilot/concepts/agents/code-review>
- [14] GitHub Docs. Application card: GitHub Copilot Agents. <https://docs.github.com/en/copilot/responsible-use/agents>
- [16] Microsoft Azure Blog. Agentic DevOps: Evolving software development with GitHub Copilot and Microsoft Azure. 2025. <https://azure.microsoft.com/en-us/blog/agentic-devops-evolving-software-development-with-github-copilot-and-microsoft-azure/>
- [17] Microsoft for Developers. Agentic DevOps in action: Reimagining every phase of the developer lifecycle. 2025. <https://developer.microsoft.com/blog/reimagining-every-phase-of-the-developer-lifecycle/>
- [23] Anthropic. Anthropic Economic Index: AI's impact on software development. 2025-04-28. <https://www.anthropic.com/research/impact-software-development>
- [24] Anthropic. How Claude Code is used in practice. 2026-06-16. <https://www.anthropic.com/research/claude-code-expertise>
- [25] Anthropic. Effective context engineering for AI agents. 2025-09-29. <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
- [27] Anthropic. Best practices for Claude Code. Claude Code Docs. <https://code.claude.com/docs/en/best-practices>
- [31] Gartner. Gartner Says the Market for Enterprise AI Coding Agents Is Entering a New Phase of Expansion and Competitive Realignment. 2026-05-20. <https://www.gartner.com/en/newsroom/press-releases/2026-05-20-gartner-says-the-market-for-enterprise-ai-coding-agents-is-entering-a-new-phase-of-expansion-and-competitive-realignment>
- [35] METR. Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity. 2025-07-10. <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/> (paper: <https://arxiv.org/abs/2507.09089>)
- [37] Stack Overflow. 2025 Developer Survey: AI. <https://survey.stackoverflow.co/2025/ai>
- [46] Arabat, A., Sayagh, M. Toward Instructions-as-Code: Understanding the Impact of Instruction Files on Agentic Pull Requests. arXiv:2606.13449, 2026-06-11. <https://arxiv.org/abs/2606.13449>
- [47] Denisov-Blanch, Y., Agarwal, S., Azaletskiy, P., He, H., Schaeffer, R., Miranda, B., Vasilescu, B., Koyejo, S. A Few Pages of Markdown: Committed AI Configuration and Lower Quality Cost after Coding-Agent Adoption. arXiv:2608.25241, 2026-08-26. <https://arxiv.org/abs/2608.25241>
- [48] Shen, J. H., Tamkin, A. How AI Impacts Skill Formation. arXiv:2601.20245, 2026-01-28. <https://arxiv.org/abs/2601.20245> (Anthropic summary: <https://www.anthropic.com/research/AI-assistance-coding-skills>)
- [50] Takerngsaksiri, W., Duong, N., Barnett, S. Who Finishes the Job? A Study of Follow-Up Fixes and Commit Authorship on AI Coding Agent Pull Requests. arXiv:2609.26847, 2026-09-22. <https://arxiv.org/abs/2609.26847>
- [52] Sakib, A. H. M. N., Banik, D., Jadliwala, M. Trust but Verify? Uncovering the Security Debt of Autonomous Coding Agents. arXiv:2607.12428, 2026-07-14. <https://arxiv.org/abs/2607.12428>
- [54] Selvanayagam, N., Ghaleb, T. A. AI-to-AI Code Reviews of GitHub Pull Requests. arXiv:2608.21311, 2026-08-21. <https://arxiv.org/abs/2608.21311>

**[55]** Stolze, M., Strässle, M. When Review Alone No Longer Scales: Layered Supervision in AI-Assisted Software Engineering. arXiv:2608.26316, 2026-08-26. <https://arxiv.org/abs/2608.26316>

**[58]** Farrag, S. E. The Productivity-Reliability Paradox: Specification-Driven Governance for AI-Augmented Software Development. arXiv:2605.01160, 2026-05-01. <https://arxiv.org/abs/2605.01160>