



Contoso Engineering (illustrative mock)

Roadmap AI-SDLC G2

Planejar, construir e revisar

DATA DO ASSESSMENT	2026-09-27
VERSÃO DO FRAMEWORK	2.0.1
RESPONDENTES	14
GERADO EM	2026-09-27

G2: Planejar, construir e revisar

ID	DIMENSÃO	SCORE	NÍVEL	ALVO	GAP	PRIORIDADE	HORIZONTE
D3	Planejar, especificar e desenhar	2.09	L2 Adotando	3.00	0.91	P2 Médio	Semestre
D4	Code e engenharia de contexto	2.72	L3 Escalando	3.00	0.28	P3 Baixo	Backlog / monitorar
D5	Review, qualidade e testes	2.10	L2 Adotando	3.00	0.90	P2 Médio	Semestre

D3: Planejar, especificar e desenhar

em agentic coding, "as pessoas tomam a maior parte das decisões de planejamento (o que fazer) e Claude toma a maior parte das decisões de execução (como fazer)" [24]; a qualidade da definição da tarefa impulsiona a qualidade da saída do agente [8], [27].

Comece por aqui

D3-Q1 IA no refinamento de backlog (2.00, L2)

Meta L3: A maioria das equipes usa IA para redigir ou melhorar itens de trabalho; critérios de aceite são obrigatórios antes do trabalho começar.

Depois L4: A qualidade dos itens de trabalho (clareza, testabilidade) é medida e vinculada a retrabalho e cycle time. [16][17]

D3-Q2 Especificação antes da implementação (2.00, L2)

Meta L3: Planos ou specs são armazenados no repositório ou vinculados à issue, e são revisados por um humano antes da implementação pelo agente.

Depois L4: Specs são o contrato para verificação automatizada (testes, checks) e são mantidas sincronizadas com o code. [24][27][58]

D3-Q5 Foco centrado no usuário (2.07, L2)

Meta L3: Itens de trabalho referenciam o problema do usuário e a medida de sucesso; feedback é revisado antes da priorização.

Depois L4: Métricas de resultado do usuário fazem parte da definition of done para entrega assistida por IA. [1][3]

Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S3 App Modernization (P1 Alto, Próximo trimestre)

Todas as perguntas desta dimensão

ID	PERGUNTA	SCORE	N	NA	EVIDÊNCIAS
D3-Q1	IA no refinamento de backlog	2.00	13	1	2
D3-Q2	Especificação antes da implementação	2.00	12	2	6
D3-Q3	Escopo de tarefas para agentes	2.15	13	1	3
D3-Q4	Decisões de arquitetura e design	2.15	13	1	4
D3-Q5	Foco centrado no usuário	2.07	14	0	4
D3-Q6	Modernização assistida por IA	2.14	14	0	7

D4: Code e engenharia de contexto

GitHub mede a profundidade de adoção como uma progressão de "Code first" para "Agent first" e "Multi-agent" [6]; a Anthropic descreve contexto como "um recurso finito com retornos marginais decrescentes" [25].

Comece por aqui

D4-Q4 Instruções de repositório (2.50, L3) não verificado

Meta L3: A maioria dos repositórios ativos tem instruções estruturadas (build, test, convenções, restrições) com um responsável; mudanças passam por PR review; arquivos são atualizados quando o codebase muda, em vez de serem commitados uma vez.

Depois L4: Instruções são geradas a partir de uma base compartilhada, verificadas quanto a desatualização, e seu efeito na taxa de merge de agentes e na qualidade de code é medido, já que arquivos de instrução sozinhos não garantem melhores resultados. [2][8][25][46][47]

D4-Q1 Profundidade do uso de IA entre superfícies (2.62, L3) não verificado

Meta L3: Muitos engenheiros usam regularmente pelo menos uma superfície de agente do GitHub ("Agent first"), confirmado por métricas de uso.

Depois L4: Uso multi-agent é normal ("Multi-agent"), com distribuição de coortes rastreada mensalmente. [6]

D4-Q2 Modo agente para trabalho multi-file (2.64, L3)

Meta L3: Agent mode é o padrão para refactors e features multi-file na maioria das equipes; mudanças são revisadas no diff antes do commit.

Depois L4: Equipes compartilham padrões de agent mode que funcionam e rastreiam onde ele falha; permissões de ferramentas são ajustadas por repositório. [6][27]

Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S6 Agentic Activation (P2 Médio, Semestre)

Todas as perguntas desta dimensão

ID	PERGUNTA	SCORE	N	NA	EVIDÊNCIAS
D4-Q1	Profundidade do uso de IA entre superfícies não verificado	2.62	13	1	5
D4-Q2	Modo agente para trabalho multi-file	2.64	14	0	7
D4-Q3	Delegação a coding agents não verificado	2.67	12	2	4
D4-Q4	Instruções de repositório não verificado	2.50	12	2	5
D4-Q5	Prompts, agentes e skills reutilizáveis não verificado	2.79	14	0	4
D4-Q6	Governança de MCP servers não verificado	2.79	14	0	5
D4-Q7	Acesso de IA ao conhecimento interno não verificado	3.08	12	2	3
D4-Q8	Seleção e roteamento de modelos	2.69	13	1	7

D5: Review, qualidade e testes

DORA vincula o volume de mudanças impulsionadas por IA à instabilidade, a menos que existam sistemas de controle fortes [3]; GitHub exige revisão humana antes que PRs de agentes sejam mergeados [7]; 46% dos desenvolvedores desconfiam da precisão da saída de IA [37].

Comece por aqui

D5-Q6 Cultura de verificação e confiança calibrada (1.77, L2)

Meta L3: Diretrizes de review explicam o que verificar na saída de IA; confiança na saída de IA faz parte da pesquisa com desenvolvedores.

Depois L4: Confiança e precisão são comparadas com dados reais de defeitos, e a orientação é atualizada onde divergem. [3][35][37][48][52]

D5-Q3 Mesmos quality gates para code de IA e humano (2.00, L2)

Meta L3: Checks exigidos são aplicados por rulesets nos protected branches da maioria dos repositórios, sem bypass para identidades de agentes.

Depois L4: Gates são policy as code, aplicados em todos os repositórios (>90%) e revisados após incidentes. [3][7][31][50][55]

D5-Q1 AI-assisted code review (2.07, L2)

Meta L3: AI review executa automaticamente na maioria dos PRs; equipes rastreiam sugestões úteis versus descartadas.

Depois L4: Regras de review são ajustadas por repositório a partir dos resultados de sugestões; tempo de review e defeitos escapados são rastreados; PRs em que apenas IA revisou code criado por IA são visíveis e governados. [6][12][54][55]

Estratégias recomendadas

- S5 GitHub Copilot Acceleration (P2 Médio, Semestre)
- S7 Security & Governance (P2 Médio, Semestre)

Todas as perguntas desta dimensão

ID	PERGUNTA	SCORE	N	NA	EVIDÊNCIAS
D5-Q1	AI-assisted code review	2.07	14	0	6
D5-Q2	Human-in-the-loop para mudanças de agentes	2.07	14	0	6
D5-Q3	Mesmos quality gates para code de IA e humano	2.00	13	1	2
D5-Q4	Lotes pequenos	2.17	12	2	7
D5-Q5	Testes assistidos por IA	2.31	13	1	2
D5-Q6	Cultura de verificação e confiança calibrada	1.77	13	1	8
D5-Q7	Saúde do code gerado por IA	2.29	14	0	2

Referências

1. DORA. DORA AI Capabilities Model. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/>
2. DORA. DORA AI Capabilities Model: Survey Questions. Google Cloud, 2025. <https://dora.dev/ai/capabilities-model/questions/>
3. Google Cloud. Announcing the 2025 DORA Report: State of AI-Assisted Software Development. 2025. <https://cloud.google.com/blog/products/ai-machine-learning/announcing-the-2025-dora-report>
4. GitHub Docs. GitHub Copilot usage metrics. <https://docs.github.com/en/copilot/concepts/copilot-metrics>
5. GitHub Docs. Risks and mitigations for GitHub Copilot cloud agent. <https://docs.github.com/en/enterprise-cloud@latest/copilot/concepts/agents/cloud-agent/risks-and-mitigations>
6. GitHub Docs. Best practices for using GitHub Copilot to work on tasks. <https://docs.github.com/enterprise-cloud@latest/copilot/tutorials/cloud-agent/get-the-best-results>
7. GitHub Docs. About GitHub Copilot code review. <https://docs.github.com/copilot/concepts/agents/code-review>
8. Microsoft Azure Blog. Agentic DevOps: Evolving software development with GitHub Copilot and Microsoft Azure. 2025. <https://azure.microsoft.com/en-us/blog/agentic-devops-evolving-software-development-with-github-copilot-and-microsoft-azure/>
9. Microsoft for Developers. Agentic DevOps in action: Reimagining every phase of the developer lifecycle. 2025. <https://developer.microsoft.com/blog/reimagining-every-phase-of-the-developer-lifecycle/>
10. Anthropic. How Claude Code is used in practice. <https://www.anthropic.com/research/claude-code-expertise>
11. Anthropic. Effective context engineering for AI agents. <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
12. Anthropic. Best practices for Claude Code. <https://www.anthropic.com/engineering/claude-code-best-practices>
13. Gartner. Gartner Says the Market for Enterprise AI Coding Agents Is Entering a New Phase of Expansion and Competitive Realignment. 2026-05-20. <https://www.gartner.com/en/newsroom/press-releases/2026-05-20-gartner-says-the-market-for-enterprise-ai-coding-agents-is-entering-a-new-phase-of-expansion-and-competitive-realignment>
14. METR. Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity. 2025-07-10. <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/> (paper: <https://arxiv.org/abs/2507.09089>)
15. Stack Overflow. 2025 Developer Survey: AI. <https://survey.stackoverflow.co/2025/ai>
16. Arabat, A., Sayagh, M. Toward Instructions-as-Code: Understanding the Impact of Instruction Files on Agentic Pull Requests. arXiv:2606.13449, 2026-06-11. <https://arxiv.org/abs/2606.13449>
17. Denisov-Blanch, Y., Agarwal, S., Azaletskiy, P., He, H., Schaeffer, R., Miranda, B., Vasilescu, B., Koyejo, S. A Few Pages of Markdown: Committed AI Configuration and Lower Quality Cost after Coding-Agent Adoption. arXiv:2608.25241, 2026-08-26. <https://arxiv.org/abs/2608.25241>
18. Shen, J. H., Tamkin, A. How AI Impacts Skill Formation. arXiv:2601.20245, 2026-01-28. <https://arxiv.org/abs/2601.20245> (Anthropic summary: <https://www.anthropic.com/research/AI-assistance-coding-skills>)
19. Takerngsaksiri, W., Duong, N., Barnett, S. Who Finishes the Job? A Study of Follow-Up Fixes and Commit Authorship on AI Coding Agent Pull Requests. arXiv:2609.26847, 2026-09-22. <https://arxiv.org/abs/2609.26847>
20. Sakib, A. H. M. N., Banik, D., Jadliwala, M. Trust but Verify? Uncovering the Security Debt of Autonomous Coding Agents. arXiv:2607.12428, 2026-07-14. <https://arxiv.org/abs/2607.12428>
21. Selvanayagam, N., Ghaleb, T. A. AI-to-AI Code Reviews of GitHub Pull Requests. arXiv:2608.21311, 2026-08-21. <https://arxiv.org/abs/2608.21311>
22. Stolze, M., Strässle, M. When Review Alone No Longer Scales: Layered Supervision in AI-Assisted Software Engineering. arXiv:2608.26316, 2026-08-26. <https://arxiv.org/abs/2608.26316>
23. Farrag, S. E. The Productivity-Reliability Paradox: Specification-Driven Governance for AI-Augmented Software Development. arXiv:2605.01160, 2026-05-01. <https://arxiv.org/abs/2605.01160>